



Universidade Federal do ABC

**Centro de Engenharia, Modelagem e Ciências Sociais Aplicadas**  
**Engenharia de Energia - Trabalho de Graduação III**

**Previsão de Demanda de Potência Elétrica Aplicada ao  
Planejamento dos Sistemas Hidrotérmicos de Potência**

***Discente:** Joana D`arc Aparecida da Costa*

***Docente:** Dra. Patrícia Teixeira Leite Asano (CECS)*

**Santo André - SP, 2017**

**Joana D`arc Aparecida da Costa - 11162509**

## **Previsão de Demanda de Potência Elétrica Aplicada ao Planejamento dos Sistemas Hidrotérmicos de Potência**

Monografia apresentada à Universidade Federal do ABC, como parte dos requisitos necessários à aprovação na disciplina Trabalho de Graduação III.

***Docente:** Dra. Patrícia Teixeira Leite Asano.*

**Santo André, Dezembro de 2017**

Ficha Catalográfica:

COSTA, JOANA D'ARC APARECIDA

Título: Previsão de Demanda de Potência Elétrica Aplicada ao Planejamento dos Sistemas Hidrotérmicos de Potência / Joana D'arc Aparecida da Costa – Santo André: Universidade Federal do ABC - UFABC, 2017. 35 p.

Orientador: Patrícia Teixeira Leite Asano.

Monografia – Universidade Federal do ABC. Centro de Engenharia, Modelagem e Ciências Sociais Aplicadas – CECS.

1. Sistema Hidrotérmico de Potência 2. Séries Temporais de Demanda de Potência 3. Redes Neurais 4. Planejamento Energético. Costa, Joana D'arc Aparecida. Graduação em Engenharia de Energia, 2017. Previsão de Demanda de Potência Elétrica Aplicada ao Planejamento dos Sistemas Hidrotérmicos de Potência.

**Joana D`arc Aparecida da Costa**

Este trabalho foi avaliado e aprovado para a conclusão do Curso de Engenharia de Energia na Universidade Federal do ABC – UFABC.

**Santo André – SP, 01 de Dezembro de 2017**

Profa. Dra. Cristina Autuori Tomazetti  
Coordenadora do Curso

**BANCA EXAMINADORA**

---

Profa. Dra. Patrícia Teixeira Leite Asano  
Orientadora

---

Fernando Toledo

---

Sunny Jonathan

Este exemplar foi revisado e alterado em relação à versão original de acordo com as observações levantadas pela banca no dia da defesa, sob responsabilidade única do autor e com a anuência de seu orientador.

Santo André, 05 de Dezembro de 2017.

---

**Joana D`arc Aparecida da Costa (Autor)**

---

**Patrícia Teixeira Leite Asano (Orientadora)**

Dedico este trabalho a Professora Dra. Patrícia Teixeira Leite Asano por todo o apoio,  
acompanhamento e compreensão, e a meus pais.

## RESUMO

Este trabalho aplica a técnica de inteligência computacional, Rede Neural Artificial, em modelos de previsão de demanda para o Sistema Elétrico Brasileiro, destinada ao planejamento dos Sistemas Hidrotérmicos de Potência. Os estudos de previsão de demanda foram realizados na ferramenta Tool Box Neural Net Time Series no Software MatLab. O principal objetivo foi estudar o comportamento das séries históricas frente ao comportamento não linear aplicado às Redes Neurais. A base de dados contemplou a demanda de potência mensal referente ao período de Janeiro de 2000 a Dezembro de 2016. Em um primeiro momento, os padrões de entrada foram os dados de Janeiro de 2000 a Dezembro de 2014. No segundo momento, o período de Janeiro de 2015 a Dezembro de 2016 foram escolhidos para a validação dos resultados. Por fim, os resultados alcançados foram comparados com os resultados esperados e foi feita uma breve discussão referente a importância da previsão de demanda para o planejamento do sistema hidrotérmico.

**Palavras-chave:** Sistema Hidrotérmico de Potência, Séries Temporais de Demanda, Redes Neurais, Planejamento Energético.

## ABSTRACT

This study applies the computational intelligence technique, Artificial Neural Network, in demand forecast models for the Brazilian Electrical System, for the planning of Hydrothermal Power Systems. Demand forecasting studies were performed on the Tool Box Neural Net Time Series in MatLab Software. The main objective was to study the behavior of the historical series against the nonlinear behavior applied to the Neural Networks. The database included monthly power demand for the period from January 2000 to December 2016. First of all, the input patterns were the data from January 2000 to December 2014. Then, the period from January 2015 to December 2016 was chosen for the validation of the results. Finally, the results obtained were compared with the expected results and a brief discussion was made regarding the importance of forecasting demand for hydrothermal system planning.

**Keywords:** Hydrothermal Power System, Time Series of Demand, Neural Networks, Energy Planning.




## SUMÁRIO

<b>1</b>	<b>Introdução .....</b>	<b>10</b>
<b>2</b>	<b>Referencial Teórico .....</b>	<b>11</b>
<b>3</b>	<b>Objetivos.....</b>	<b>17</b>
<b>4</b>	<b>Metodologia .....</b>	<b>17</b>
<b>5</b>	<b>Resultados .....</b>	<b>18</b>
<b>6</b>	<b>Conclusão .....</b>	<b>27</b>
<b>7</b>	<b>Referências Bibliográficas .....</b>	<b>29</b>
<b>8</b>	<b>Anexo .....</b>	<b>30</b>

# 1 INTRODUÇÃO

A capacidade total de potência instalada no Brasil atingiu 150,34 GW. Sendo que 68,1% da energia elétrica brasileira é proveniente da geração hidráulica, 18,3% proveniente da geração térmica e 13,61% de biomassa, eólica e solar [1]. Como pode ser visto na figura 1.



**Figura 1:** Matriz de Energia Elétrica Brasileira (BEN, 2017)

Isso significa que a geração hidrotérmica é de suma importância para a produção de energia elétrica no Brasil. Além disso, é previsto que até 2050 a demanda de energia irá triplicar. Desta forma, será necessário investir na geração de energia elétrica e realizar um bom planejamento do sistema [2]. Uma das variáveis a ser levada em consideração no planejamento é a previsão de demanda de energia elétrica.

A demanda de potência é medida em quilowatt (W) corresponde a maior demanda de potência ativa, verificada por medição, integralizada em intervalos de 15 minutos e é faturada pelo valor medido durante o período de fornecimento, geralmente de 30 dias [3].

Diante da importância da previsão de demanda para o planejamento energético, a aplicação de teorias que usam como base as séries temporais é um fator de grande viabilidade, dentre as quais se destaca a metodologia de Redes Neurais Artificiais (RNA). Outras metodologias também podem ser utilizadas para previsão de demanda e consumo de energia elétrica, tais como, modelos autoregressivos integrados de média móvel (ARIMA), modelos não lineares autoregressivos integrados de média móvel (NARIMA) e redes neuro-fuzzy (RNF) [4].

As redes neurais apresentam grande habilidade em aprender padrões complexos e capacidade de lidar com a não linearidade e não estacionaridade presentes em algumas séries temporais. O uso de RNA na previsão de séries temporais é cada vez mais frequente em pesquisas.

Oliveira et al. (2010) aplicaram a metodologia de redes neurais para prever a produção de álcool, no Brasil, no ano de 2006. Neste estudo foi feito uma comparação entre os resultados

obtidos por meio da rede neural com os obtidos utilizando outras técnicas de séries temporais, tendo a rede neural obtido melhores resultados [5].

Além deste trabalho, Villamagna (2013) realizou um estudo sobre o consumo e a demanda de energia elétrica da Universidade Federal de Lavras (UFLA), referente ao período de Janeiro de 1995 a Dezembro de 2011, utilizando-se métodos de Box e Jenkins e Redes Neurais Artificiais. Pela análise comparativa, as redes neurais foram mais eficientes para este estudo [6] [7].

Redes neurais artificiais são algoritmos computacionais baseados em uma aproximação do modelamento do cérebro humano [8]. Unidades simples chamadas neurônios são interligadas para formar uma rede. As redes neurais, ao contrário das técnicas tradicionais de computação, não são programadas com algoritmos para resolver problemas. Elas aprendem a solução de um problema, e para tanto devem ser treinadas através da apresentação de exemplos dessa solução.

Sendo assim, este projeto de graduação de curso em Engenharia de Energia irá analisar a performance de aprendizado da RNA frente ao comportamento não linear dos dados. A base de dados irá contemplar a demanda de potência elétrica referente ao período de Janeiro de 2000 a Dezembro de 2016, para realizar um estudo da previsão de demanda futura de potência elétrica no Brasil para o planejamento da operação dos sistemas hidrotérmicos de potência.

## **2 REFERENCIAL TEÓRICO**


Para a operação de uma rede neural artificial, o conjunto de neurônios artificiais é uma unidade de processamento de informação representada por grafos. Inspirados no funcionamento do neurônio biológico, os neurônios artificiais conectados em redes têm a capacidade de aprender e generalizar, mas é importante reconhecer que são bastante primitivos, em relação à complexidade do cérebro humano.

### **2.1 Neurônio biológico:**

Simplificadamente, o neurônio biológico é composto por um corpo celular, dendritos e axônio. A informação do neurônio é transmitida sob a forma de impulsos nervosos em sentido unidirecional (corpo celular, axônio, dendritos e neurônio seguinte). Os sinais são transmitidos de neurônio pré-sináptico, por meio de junções interneurais chamadas de sinapses.

Nas sinapses químicas, o primeiro neurônio secreta, na fenda sináptica, uma substância química chamada neurotransmissor, que atua sobre proteínas receptoras localizadas na membrana do neurônio seguinte para excitá-lo ou inibi-lo.


O terminal pré-sináptico tem estruturas internas para a função excitatória ou inibitória da sinapse: as vesículas sinápticas, que contêm substâncias transmissoras, as quais são liberadas na fenda sináptica. Essas substâncias se excitam se a membrana neuronal do pós-sináptico contiver receptores excitatórios e o inibem se ela tiver receptores inibitórios. A figura 2 ilustra a estrutura simplificada de um neurônio.



**Figura 2:** Estrutura simplificada de um neurônio biológico.

## 2.2 Neurônio artificial:

É possível observar na figura 3 um modelo no qual podem ser vistas sinapses, representadas pelas entradas ( $x_1, x_2, x_m$ ), e pesos sinápticos ( $w_{k1}, w_{k2}, w_{km}$ ), somatório e função de ativação ( $f(\cdot)$ ). Cada sinapse é caracterizada por um estímulo de entrada multiplicado pelo seu peso sináptico correspondente. Depois desta multiplicação, cada sinal de entrada é somado e o resultado, é então, aplicado a uma função de ativação que restringe a saída do neurônio.



**Figura 3:** Modelo geral do neurônio artificial.

Matematicamente, um neurônio  $k$  é escrito como:

$$u_k = \sum_{j=1}^m w_{jk} x_j + b_k$$

A função é calculada pela combinação linear dos pesos e das entradas ou, equivalentemente, ao produto escalar do vetor de pesos  $w^T = [w_{k1} \ w_{k2} \ \dots \ w_{km}]$  e vetor de entrada  $x^T = [x_1 \ x_2 \ \dots \ x_m]$

$$u_k = w^T x + b_k$$

A saída é obtida aplicando-se uma função de ativação

$$y_k = f(u_k)$$

Sendo que

$x_1, x_2, \dots, x_m$  são os sinais de entrada, números reais ou binários

$w_1, w_2, \dots, w_k$  são os pesos sinápticos que indicam a força de entrada para a resolução de um problema, valores positivos ou negativos.

$u_k$  é o resultado da junção somadora dos sinais de entrada, ponderados pelas respectivas sinapses.

$f(x)$  é a função de ativação que restringe a amplitude da saída do neurônio a um valor finito.

$b_k$  é o viés, que possui o efeito de aumentar ou diminuir a entrada da função de ativação.

$y_k$  é o sinal de saída do neurônio.

Conforme Haykyn (2001), o conhecimento é adquirido a partir de seu ambiente, por meio de um processo de aprendizagem e os pesos sinápticos são utilizados para armazenar o conhecimento adquirido [9].

O processo de aprendizado consiste em ajustar os pesos sinápticos e bias, de forma que a aplicação de um conjunto de entradas produzam um conjunto de saídas desejadas. O tipo de aprendizado é determinado pela maneira como os parâmetros são modificados.

O processo em que a rede é treinada para fornecer a saída desejada a um estímulo de entrada específico é denominado aprendizado supervisionado, no qual não há uma saída específica em relação aos estímulos de entrada. A rede se auto-organiza em relação às particularidades do conjunto de entrada.

Neste trabalho, foi utilizado o trabalho supervisionado para treinar a rede. A seguir, será descrito o algoritmo de aprendizagem utilizado e os principais tipos de funções de ativação e arquiteturas da rede [10].


### 2.3 Funções de ativação:

A função de ativação é utilizada para definir a saída do neurônio a partir dos valores dos pesos e de entradas. Os tipos principais são:

- Função limiar ou degrau;
- Função sigmoide;
- Função linear.

#### ➤ Função limiar ou degrau:


Esta função assume valor 1 quando o campo local induzido do neurônio é não negativo e 0, caso contrário, as sinapses correspondentes são inibitórias. A figura 4 apresenta o gráfico desta função.



**Figura 4:** Função limiar ou degrau.

➤ **Função sigmoide:**


Esta função possui um comportamento crescente que exige um equilíbrio entre o comportamento linear e não linear. A figura 5 apresenta a função sigmoide.



**Figura 5:** Função sigmoide.

➤ **Função linear:**

A função linear é apresentada na figura 6.




**Figura 6:** Função linear.

### 2.3 Arquitetura da rede:

Arquitetura da rede é a forma como os neurônios estão arranjados. Na estrutura da rede neural os neurônios estão dispostos em camadas, eles podem estar em uma única camada ou em redes alimentadas com múltiplas camadas.


As redes com camada única, conforme representada na figura 7, tem-se a camada de entrada que se projeta sobre a camada de saída de neurônios. Esta arquitetura são aplicadas em reconhecimento de padrões e memória associativa. Essas também são chamadas de perceptron. Essas redes foram utilizadas em problemas de classificação de padrões linearmente separáveis. Esses problemas são aqueles na qual a solução pode ser obtida por meio de uma reta, que divide o espaço de soluções em regiões ou classes [11].



**Figura 7:** Rede neural de camada única. Rede alimentada com quatro neurônios de entrada e dois na camada de saída.

Porém, existem conjuntos de dados que não são separáveis apenas por uma reta, e sim por um conjunto de retas ou regiões espaciais mais complexas. Sendo assim, o algoritmo de treinamento do perceptron não converge. Logo, uma rede de múltiplas camadas é utilizada.

As redes com camadas múltiplas diferenciam-se pela presença de uma ou mais camadas ocultas de neurônios e cada neurônio da rede inclui uma função não linear, por exemplo, a função sigmoide. As camadas ocultas se intercalam entre a entrada e a saída, de forma que a rede é capaz de extrair estatísticas de ordem elevada. Este tipo de arquitetura é utilizada na aproximação de funções, reconhecimento de padrões, identificação e controle. Ela tem sido aplicada em problemas complexos, por meio do treinamento supervisionado com um algoritmo conhecido como algoritmo de retropropagação de erro (error backpropagation). A figura 8 ilustra este tipo de arquitetura.



**Figura 8:** Rede neural de camadas múltiplas. Rede com quatro neurônios na camada de entrada, quatro na camada intermediária e dois na saída.

A rede de múltiplas camadas, juntamente com o algoritmo de treinamento por retropropagação, soluciona problemas não linearmente separáveis. Logo, é mais aplicável a um número maior de problemas reais, diagnósticos médico, reconhecimento de caracteres e previsão de séries temporais.

O algoritmo de retropropagação é um algoritmo de aprendizado supervisionado, baseado na correção de erros. E pode ser resumido em dois tipos de processamento:

- Processamento para frente: o sinal é propagado e aparece na camada de saída;
- Processamento de retroprogramação: o erro é corrigido camada a camada, começando pela camada de saída até a primeira camada oculta.

O objetivo é encontrar na superfície de erro um mínimo global, ou seja, valores para os pesos sinápticos que minimizam os erros da rede.

O desempenho de aprendizagem da rede é medido através do erro quadrático médio. O processo de aprendizagem é repetido para cada exemplo de treinamento apresentado à rede, até que um critério de parada seja satisfeito. Um dos critérios mais utilizados é definir o número máximo de épocas de treinamento ou um erro de tolerância, ou seja, assim que a variação do erro quadrático médio de uma época para outra atinja um valor suficientemente pequeno [12].



## 2 OBJETIVOS

O objetivo deste trabalho de graduação foi estudar uma metodologia que possa auxiliar na previsão da demanda de potência, porém os objetivos específicos do Trabalho de Graduação foram:

- Coletar dados de demanda de potência elétrica do Brasil e de suas sub-regiões (MW);
- Definir uma ferramenta para análise dos dados;
- Estudar a técnica de inteligência artificial a partir de Redes Neurais para a auxiliar na previsão de demanda.

## 3 METODOLOGIA

Os dados para este trabalho foram coletados no site do Operador Nacional do Sistema (ONS), a série de estudo consta com 204 observações mensais, referente a demanda de potência de Janeiro de 2010 a Dezembro de 2016 [13].

Conforme o levantamento bibliográfico apresentado na Introdução e no Referencial Teórico, as Redes Neurais apresentaram resultados satisfatórios, em estudos anteriores, para a previsão de demanda baseada em séries temporais. Desta forma, foi definido utilizar a teoria de Redes Neurais Artificiais no software Matlab para a previsão de demanda de potência.

Existem algumas dificuldades na utilização de RNA na previsão de séries temporais referentes à determinação da arquitetura ótima da rede, tais como o número de camadas, o número de neurônios, a taxa de aprendizagem e o tempo de treinamento. Desta forma, o tratamento adequado dos dados, bem como uma análise detalhada da série a ser estudada, é um dos fatores fundamentais na obtenção de resultados satisfatórios utilizando RNA.

Sendo assim, os dados de demanda de potência das quatro sub-regiões do Brasil, correspondente ao período de Janeiro de 2000 a Dezembro de 2016, foram analisados para definir o melhor tratamento.

Para ajustar as séries de demanda de potência de acordo com a metodologia de Redes Neurais Artificiais (RNA), foi necessário pré-estabelecer alguns parâmetros e critérios, tais como:

- Separar os dados para treinamento e teste/validação do treinamento;
- Escolher a arquitetura da rede (escolha do número de neurônios na camada de entrada e na camada intermediária, número de camadas escondidas);
- Escolha do algoritmos de treinamento;
- Definição da função de ativação;
- Escolha da taxa de aprendizagem;
- Estabelecimento de um critério de parada.

Foram feitos 8 (oito) testes na ferramenta Toolbox Neural Net Time Series do Matlab. Para utilizar o método de RNA, primeiramente, foi preciso separar os dados a serem analisados, em duas partes. Os dados de Janeiro de 2000 a Dezembro de 2014 foram utilizados para treinar a rede e os dados de Janeiro de 2015 a Dezembro de 2016 foram utilizados para validar/testar a rede.


A função de ativação escolhida foi a sigmoide, que fornece a saída em um intervalo positivo, visto que a demanda de potência sempre terão valores positivos, devido à sua natureza.

Foram utilizadas as redes de camadas múltiplas, cuja a arquitetura é formada pela entrada, camada intermediária e camada de saída.

O algoritmo utilizado foi o retropropagação. A taxa de aprendizagem foi de 0,01 e a constante momento foi de 0,9. O critério de parada escolhido foi o número de épocas.

## 4 RESULTADOS


A partir das informações coletadas na base de dados do Operador Nacional do Sistema (ONS) foi possível observar a tendência da curva de demanda de potência elétrica das quatro sub-regiões do Brasil, vide figura 9.



**Figura 9:** Média da demanda de potência anual (MW) nas quatro sub-regiões do Brasil.

A figura 9 apresenta a média de demanda de potência anual em MW nas quatro sub-regiões do Brasil (Sudeste-Centro Oeste, Nordeste, Sul e Norte). Pode-se observar que a sub-região SE-CO requer maior demanda de potência comparando-se com as outras regiões. Esta tendência justifica-se pois a sub-região SE-CO comporta o maior centro consumidor do Brasil, composta por indústrias, comércios e residências.


Com o intuito de comparar a demanda de potência de cada região com a demanda do Sistema Nacional Interligado foi plotado o gráfico da figura 10.



**Figura 10:** Média da demanda de potência anual (MW) nas quatro sub-regiões e no Brasil (SIN).


A figura 10 apresenta um comparativo da média da demanda de potência anual das quatro sub-regiões com a demanda total do Brasil. Pode-se observar que a demanda total de potência do Brasil segue a mesma tendência de crescimento de demanda da região SE-CO, este fato também se justifica pelo fato da região SE-CO possuir o maior centro consumidor.

Com o intuito de observar uma sazonalidade nos dados foi plotado o gráfico da demanda de potência mensal desde Janeiro de 2000 a Dezembro de 2016, para as quatro sub-regiões e a demanda total do Brasil (SIN), conforme dados da figura 11.



**Figura 11:** Demanda de potência mensal por região e no Brasil.

Analisando o comportamento da curva que representa a demanda de potência para todo o Brasil (SIN) é possível verificar uma tendência dos anos 2000 a 2008, sendo que do final do ano anterior para o próximo ano existe uma decaída na demanda, durante o ano a demanda vai crescendo e depois começa a decair novamente. Entretanto, a partir de 2010 é possível verificar um comportamento irregular com altos e baixos, mas com uma elevação da demanda no início do ano, um decaimento durante o ano e no meio do segundo semestre uma retomada do crescimento da demanda, como pode ser observado na figura 12. Estes comportamentos que a rede neural deve aprender para prever valores futuros.



**Figura 12:** Demanda de potência mensal por região e no Brasil.

A figura 12 apresenta os valores mensais de demanda de potência para cada ano. Os valores estão sobrepostos para observar a tendência descrita anteriormente. As curvas de demanda referente aos anos de 2001, 2007, 2009, 2010, 2013 e 2014 foram omitidas da figura 12 para dar mais clareza a imagem.

Utilizando a ferramenta Toolbox Neural Net Times Series do Matlab foram feitos oito treinamentos com os dados de Janeiro de 2000 a Dezembro de 2014, e os dados de Janeiro de 2015 a Dezembro de 2016 foram utilizados para testar a rede. Os treinamentos foram realizados somente com os dados SIN (Sistema Interligado Nacional). Primeiramente, os dados foram importados do Excel para o Matlab, a coluna data foi importada como “MesAno” e a coluna de demanda de

potência referente a cada mês foi importada como “Demanda”. A tabela 1 apresenta os parâmetros do Matlab da configuração da rede para os treinamentos realizados.

Parâmetros	Treinamento 1	Treinamento 2	Treinamento 3	Treinamento 4	Treinamento 5	Treinamento 6	Treinamento 7	Treinamento 8
Tipo de rede	Retropropagação	Retropropagação	Retropropagação	Retropropagação	Retropropagação	Retropropagação	Retropropagação	Retropropagação
Função de treinamento	trainlm	trainlm	trainlm	trainlm	trainlm	trainlm	traingdx	traingdx
Função de adaptação	learngdm	learngdm	learngdm	learngd	learngd	learngd	learngdm	learngdm
Função de performance	MSE	MSE	MSE	MSE	MSE	MSE	MSE	MSE
Número de camadas	2	2	3	2	2	2	3	3
Número de neurônios	12	24	12	12	12	12	12	24
Função de ativação	tansig	tansig	tansig	tansig	logsig	purelin	tansig	tansig
Épocas	1000	1000	1000	1000	1000	1000	1000	1000
Taxa de aprendizagem	0,01	0,01	0,01	0,01	0,01	0,01	0,01	0,01
Termo momento	0,9	0,9	0,9	0,9	0,9	0,9	0	0

**Tabela 1:** Arquitetura da rede para os treinamentos.

A seguir será descrito o significado de cada termo que o Matlab designa:

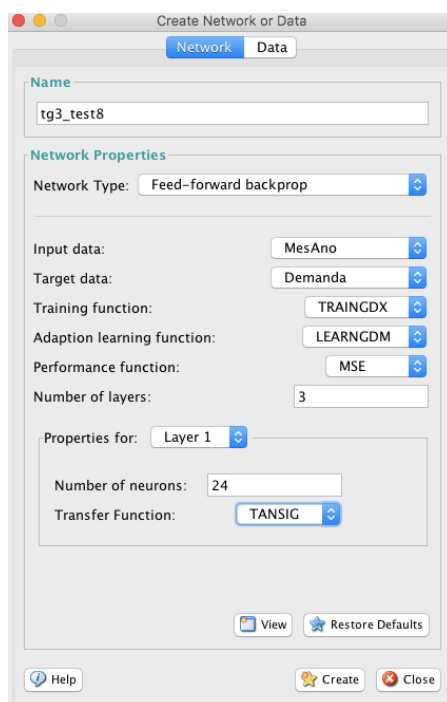
trainlm: Levenberg Marquardt backpropagation;

traingdx: Gradiente descente with momentum and adaptive learning rate backpropagation;

learngdm: Gradient descente with momentum weight and bias learning function;

MSE: Mean squared normalized error performance function;

As figuras a seguir apresentam as telas de configuração do matlab para os treinamento e testes:



**Figura 13:** Tela de criação da rede neural.

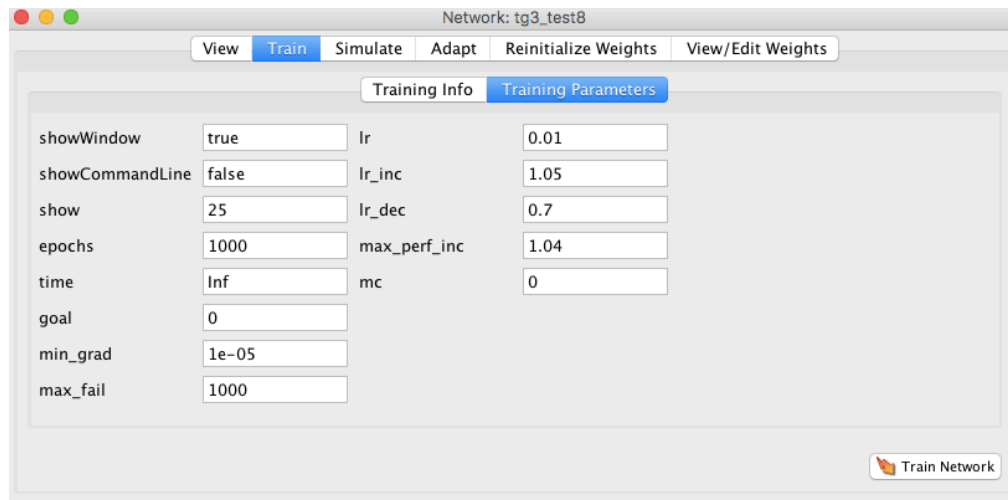


Figura 14: Tela com os parâmetros de treinamento.

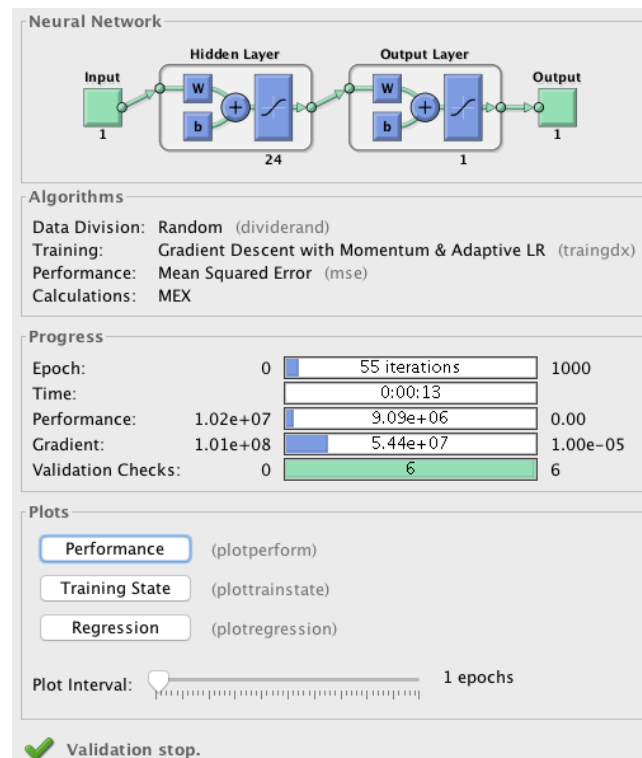
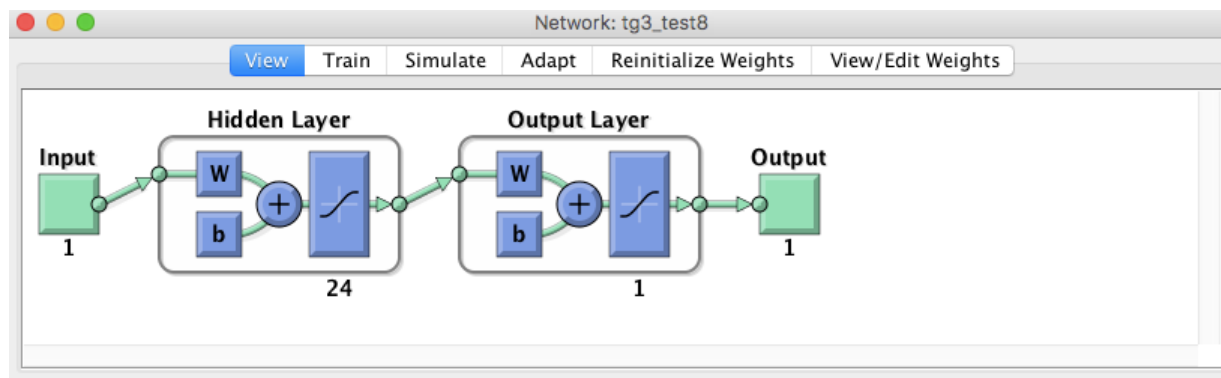



Figura 15: Tela de treinamento.




**Figura 16:** Arquitetura de uma das redes (treinamento 8).

O gráfico da figura 17 apresenta os resultados dos treinamentos comparados com os valores esperados de demanda de potência para o Sistema Interligado Nacional (SIN).



**Figura 17:** Validação dos treinamentos.

Como pode ser observado na figura 16, somente os treinamentos 1 e 7 obtiveram uma mudança de comportamento. A figura 18 apresenta o valor esperado e os resultados da validação dos treinamentos 1 e 7.



**Figura 18:** Validação dos treinamentos 1 e 7.

Como pode ser observado na figura 18, a rede treinada não aprendeu o comportamento exato apresentado pela demanda de potência do SIN. Vários treinamentos foram realizados e testados, mas todos apresentaram o mesmo comportamento da figura 18, com um comportamento crescente no início e uma estabilização no final do treinamento.

Porém, o resultado apresentado pela rede neural treinada não são valores totalmente fora dos valores esperados, mesmo porque a previsão de demanda a partir de redes neurais apresenta valores estimados que podem condizer ou não com o valor real, sendo uma estimativa.

Além disso, o Sistema Interligado Nacional (SIN) brasileiro é um sistema robusto, no qual é interdependente de outros fatores macroeconômicos e demográficos. Para uma previsão de demanda mais assertiva outros fatores poderiam ser considerados para uma previsão mais assertiva, tais como:


- Produto Interno Bruto (PIB);
- Preço da energia elétrica (R\$/MWh) (PLD);
- Crescimento populacional;
- Densidade demográfica;
- Consumo de energia elétrica;
- Série histórica de vazões;
- Investimentos futuros no setor elétrico;
- Informações técnicas de geradores térmicos e hidroelétricos;
- Potencial instalado;
- Interligações entre as sub-regiões;



Entre outros fatores que poderiam ser considerados para se construir diferentes cenários para o estudo de demanda de potência futuro [14].

O preço da energia elétrica (R\$/MWh) é um dos fatores no qual poderia ser levado em consideração para a análise e tomada de decisão quanto ao planejamento do sistema elétrico de potência. A figura 19 apresenta os valores do PLD referente a Maio de 2003 a Dezembro de 2016. O PLD (Preço de Liquidação das Diferenças) é o preço de curto prazo divulgado semanalmente pela Câmara de Comercialização de Energia Elétrica (CCEE), base para as negociações que ocorrem no mercado de curto prazo. [15]

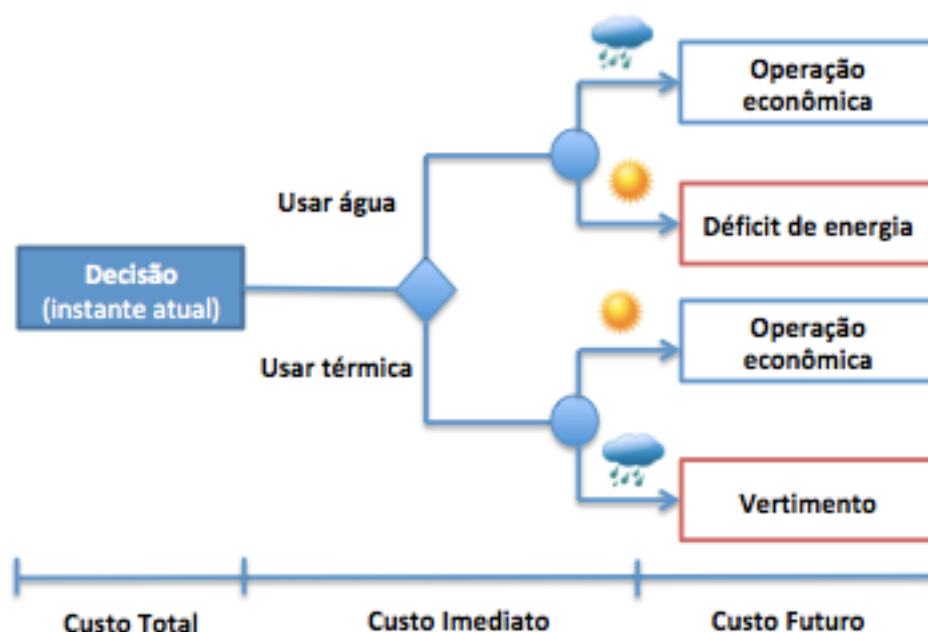
Na figura 19 é possível observar grandes picos de elevação e decaimento no período entre 2013 e 2014, estes picos também podem ser observados na figura 11 de demanda de potência anual para o SIN. Em Novembro de 2014 o PLD atingiu seu maior patamar por volta de R\$800 MWh, isto foi reflexo de uma má administração hídrica, sendo que as usinas termelétricas estavam fornecendo boa parte da demanda de energia. Além disso é possível observar o comportamento da demanda de potência e do preço da energia, sendo que em Julho de 2014 a Outubro de 2014 foi possível observar um aumento na demanda de potência, acompanhada também por um aumento do PLD, pois estava se utilizando das fontes térmicas. Porém, a partir de Novembro de 2014 observa-se um decaimento no preço da energia acompanhada com um aumento da demanda de energia. Sendo assim, a fonte de energia utilizada para atender a demanda de energia possui uma relação direta com o preço da energia, justificando a importância do planejamento energético.



**Figura 19:** PLD refere a Maio de 2003 a Dezembro de 2016.

Conforme descrito na introdução deste trabalho a previsão de demanda é de suma importância para o planejamento do sistema elétrico de potência, tanto para o planejamento e programação da operação como para o planejamento da expansão do sistema.

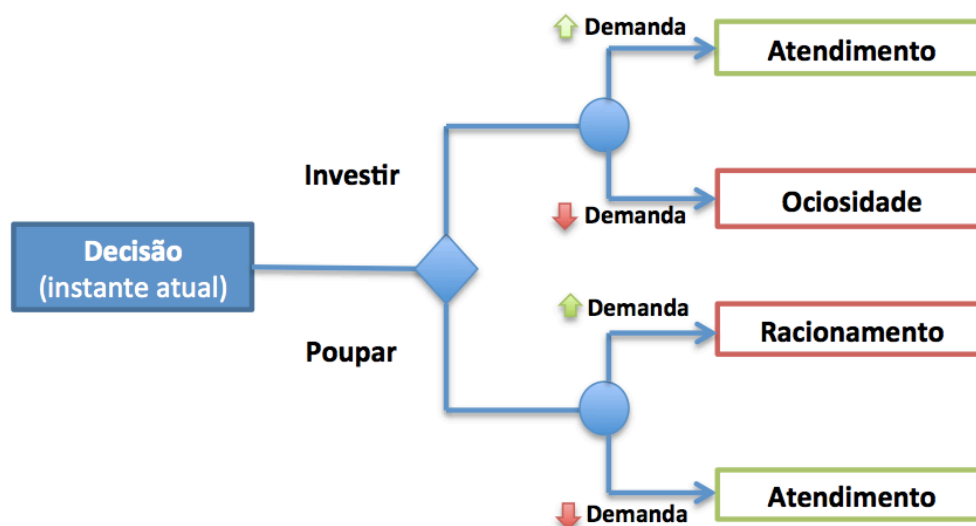
O planejamento e programação da operação envolve a tomada de decisão entre o uso imediato e o uso futuro da água. Por exemplo, se ocorrer um despacho hidroelétrico expressivo antes de um período seco, corre-se o risco de despachar térmicas de custo mais elevado no futuro; entretanto, um despacho térmico anterior a um período úmido poderá provocar vertimentos, consequentemente, ocorrerá um desperdício de energia. Isto pode ser verificado no esquema da figura 20.



**Figura 20:** Problema de decisão da operação. Fonte: ONS 2012 [16].

Sendo assim, uma operação equilibrada do sistema envolverá um compromisso entre utilizar ou não as usinas hidrelétricas. A variável de decisão é o volume de água armazenada no fim do período da operação (volume final) e a demanda futura.

Por outro lado o planejamento da expansão tem-se a relação entre o uso futuro ou imediato do capital financeiro disponível para a expansão. Isto significa que, os agentes precisam decidir entre investir agora e correr o risco de ociosidade do sistema em razão do crescimento abaixo do esperado da demanda futura, ou então postegar o investimento e arriscar-se ao racionamento, conforme pode ser observado no esquema da figura 21. [16]



**Figura 21:** A decisão do investimento. Fonte: ONS 2012 [16].

Sendo assim, a previsão de demanda é importante para o planejamento do sistema elétrico, com o intuito de mitigar o custo da operação e avaliar o risco da falta de energia.

## 5 CONCLUSÃO

Durante este Trabalho de Graduação para o curso de Engenharia de Energia, a partir dos dados da ONS, foi possível observar a tendência de crescimento de demanda de potência nas quatro sub-regiões do Brasil, Sudeste/Centro-Oeste (SE-CO), Nordeste (NE), Norte (N) e Sul (S). A sub-região SE-CO apresentou maior demanda de potência quando comparada com as outras sub-regiões. Além disso, comparando-se a sub-região SE-CO com a demanda total do Brasil, foi possível observar que a SE-CO é o carro chefe do Brasil, por possuir o maior centro consumidor (indústrias, comércios e residências).

Com base nos dados de demanda de potência do sistema interligado, foram criadas arquiteturas de redes neurais para o desenvolvimento de um programa para a previsão de demanda de potência. Os dados de Janeiro de 2000 a Dezembro de 2014, foram utilizados para o treinamento da rede, e os dados de Janeiro de 2015 a Dezembro de 2016 foram utilizados para validação do treinamento. Oito arquiteturas de redes foram criadas, porém somente duas tiveram uma mudança de comportamento considerável, mas não acompanharam o comportamento exato da curva esperada. Isto ocorreu pois, foram utilizadas somente valores de demanda de potência para a previsão. Como o Sistema Interligado Nacional brasileiro é um sistema robusto, outros fatores macroeconômicos e demográficos poderiam compor os cenários para o um estudo da previsão de demanda mais assertivo. Mesmo assim a rede neural deste trabalho não apresentou valores totalmente fora do esperado.

Por fim, durante o desenvolvimento deste trabalho foi possível estudar as séries históricas de demanda de potência do Brasil e de suas sub-regiões, aprender sobre o conceito de inteligência artificial, analisar os parâmetros importantes para a configuração de uma rede neural artificial e apresentar a importância da previsão de demanda para o planejamento do sistema elétrico.

## 6 REFERÊNCIAS BIBLIOGRÁFICAS

- [1] Balanço Energético Nacional 2017: Ano base 2017/ Empresa de Pesquisa Energética – Rio de Janeiro: EPE, 2017.
- [2] Estudo de Demanda de Energia 2050. Ano base 2014/ Empresa de Pesquisa Energética – Rio de Janeiro: EPE, 2014.
- [3] Resolução Normativa N.º 414/2010: atualizada até REN 499/2012. Agência Nacional de Energia Elétrica – Brasília: ANEEL, 2012. 202p.: il.
- [4] Campos, R.J. (2008) Previsão de séries temporais com aplicações a séries de energia elétrica. 100p. Dissertação (Mestrado em Engenharia Elétrica) – Universidade Federal de Minas Gerais, Belo Horizonte.
- [5] Oliveira, A.C.S. et al. (2010). Aplicação de Redes Neurais Artificiais na previsão da produção de álcool. Ciência e Agrotecnologia, Lavras, v.34, n2, p279 – 284.
- [6] Villamagna, M. R. (2013). Seleção de modelos se séries temporais e redes neurais artificiais na previsão de consumo e demanda de energia elétrica. Lavras: UFLA. 113p.:il.
- [7] Box, G.; Jenkins, G. (1979). Time series analysis, forecasting and control. San Francisco: Holden-Day. 575p.
- [8] Haykin, S. (1998). Neural Networks: a Comprehensive Foundation, Prentice Hall PTR Upper Saddle River, NJ, USA.
- [9] Haykin, S. (2001). Neural networks, a comprehensive foundation. New Jersey: Englewood Cliffs. 864p.
- [10] Bishop, C. M. Neural networks for pattern recognition. Oxford: Oxford University, 1997. 482 p.
- [11] Sistemas Inteligentes: Fundamentos e Aplicações. Solange Oliveira Rezende. Barueri, SP: Manole, 2005.
- [12] Inteligência Artificial. Bem Copin. Rio de Janeiro, RJ: LTC, 2010.
- [13][http://www.ons.org.br/historico/carga\\_propria\\_de\\_demanda\\_out.aspx](http://www.ons.org.br/historico/carga_propria_de_demanda_out.aspx); Ultimo acesso em 10/05/2017.
- [14] Marzano, L.G.B.; Maceira, M.E.P.; Justino,T.C.; Melo,A.C.G. (2010). Integrating Short and Long-Term Energy Expansion Planning Tools for more Resiliente Mid-Term Energy Plans for the Brazillian Interconneted System. CEPEL. UERJ. Rio de Janeiro.
- [15][https://www.ccee.org.br/portal/faces/pages\\_publico/o-quefazemos/como\\_ccee\\_atua/precos/precos\\_medios?\\_afzLoop=173153066640731#!%40%40%3F\\_afzLoop%3D173153066640731%26\\_adf.ctrl-state%3D16dyg2p69k\\_43](https://www.ccee.org.br/portal/faces/pages_publico/o-quefazemos/como_ccee_atua/precos/precos_medios?_afzLoop=173153066640731#!%40%40%3F_afzLoop%3D173153066640731%26_adf.ctrl-state%3D16dyg2p69k_43); Ultimo acesso em 04/11/2017.
- [16] Souza, R.C; Oliveira, F.C.; Ferreira, P.C; Marcato, A.L.M; Dias, B.H.; Brandi, R.S.; Ramos,T.P. (2014). Planejamento da operação de sistemas hidrotérmicos no Brasil: geração de cenários e otimização. Rio de Janeiro: Ed. PUC-Rio.

## 7 ANEXO

### ANEXO 1 - Dados de Demanda de Potência do SIN – Sistema Interligado Nacional

Ano	String to number (ano)	Demanda SIN (MW)
Jan-00	36526	49218.8
Feb-00	36557	51495
Mar-00	36586	52180.2
Apr-00	36617	54133.6
May-00	36647	54251.3
Jun-00	36678	54335
Jul-00	36708	53348.8
Aug-00	36739	53439.1
Sep-00	36770	53179
Oct-00	36800	52767.2
Nov-00	36831	51984.4
Dec-00	36861	52765
Jan-01	36892	51141.8
Feb-01	36923	53661.4
Mar-01	36951	54067.3
Apr-01	36982	55099.1
May-01	37012	54593.3
Jun-01	37043	44846
Jul-01	37073	42379.6
Aug-01	37104	41898
Sep-01	37135	42314.3
Oct-01	37165	42308.8
Nov-01	37196	42055
Dec-01	37226	42780.7
Jan-02	37257	43941.88
Feb-02	37288	46330.07
Mar-02	37316	48226.65
Apr-02	37347	49816.9
May-02	37377	49843.55
Jun-02	37408	49933.2
Jul-02	37438	49122.89
Aug-02	37469	49304.51
Sep-02	37500	49396.82
Oct-02	37530	50756.92
Nov-02	37561	49816.62
Dec-02	37591	49858.67
Jan-03	37622	49010.87
Feb-03	37653	51685.11
Mar-03	37681	51446.02
Apr-03	37712	53300.86

May-03	37742	53514.61
Jun-03	37773	53206.79
Jul-03	37803	52229.4
Aug-03	37834	51946.84
Sep-03	37865	52414.37
Oct-03	37895	52689.48
Nov-03	37926	52556.14
Dec-03	37956	52523.1
Jan-04	37987	50892.48
Feb-04	38018	53255.88
Mar-04	38047	54732.73
Apr-04	38078	55619.31
May-04	38108	55770.89
Jun-04	38139	56108.16
Jul-04	38169	55996.85
Aug-04	38200	56452.6
Sep-04	38231	56795.06
Oct-04	38261	56507.13
Nov-04	38292	55619.86
Dec-04	38322	55690.26
Jan-05	38353	53988.98
Feb-05	38384	57770.71
Mar-05	38412	58386.28
Apr-05	38443	58991.16
May-05	38473	59103.02
Jun-05	38504	57962.9
Jul-05	38534	56834.95
Aug-05	38565	58357.33
Sep-05	38596	57718.23
Oct-05	38626	58418.82
Nov-05	38657	56979.25
Dec-05	38687	56945.17
Jan-06	38718	56369.47
Feb-06	38749	59149.52
Mar-06	38777	59526.06
Apr-06	38808	60389.46
May-06	38838	59788.63
Jun-06	38869	59412.29
Jul-06	38899	59861.88
Aug-06	38930	60284.55
Sep-06	38961	59557.71
Oct-06	38991	59272.6
Nov-06	39022	58916.04

Dec-06	39052	58894.53
Jan-07	39083	58818.04
Feb-07	39114	61147.56
Mar-07	39142	62749.02
Apr-07	39173	62894.56
May-07	39203	62793
Jun-07	39234	61941.15
Jul-07	39264	61742.07
Aug-07	39295	61424.18
Sep-07	39326	61701.32
Oct-07	39356	62534.7
Nov-07	39387	60738.01
Dec-07	39417	61960.19
Jan-08	39448	59580.51
Feb-08	39479	61674.36
Mar-08	39508	63039.64
Apr-08	39539	63641.71
May-08	39569	64155
Jun-08	39600	63886.75
Jul-08	39630	63756.58
Aug-08	39661	63853
Sep-08	39692	64052.28
Oct-08	39722	63506.91
Nov-08	39753	60934.91
Dec-08	39783	59880.83
Jan-09	39814	61131.09
Feb-09	39845	62614.18
Mar-09	39873	64810.32
Apr-09	39904	61510.25
May-09	39934	62430.5
Jun-09	39965	61035.39
Jul-09	39995	61511.67
Aug-09	40026	62063.73
Sep-09	40057	62536.23
Oct-09	40087	62031.53
Nov-09	40118	67227
Dec-09	40148	65845
Jan-10	40179	66766.46
Feb-10	40210	70478.14
Mar-10	40238	69675.31
Apr-10	40269	65477.85
May-10	40299	65448.27
Jun-10	40330	64737.02
Jul-10	40360	64718.64
Aug-10	40391	65578.12
Sep-10	40422	65572.02
Oct-10	40452	65005.52

Nov-10	40483	68083.6
Dec-10	40513	68823.3
Jan-11	40544	70461.07
Feb-11	40575	70661.29
Mar-11	40603	68780.28
Apr-11	40634	68993.57
May-11	40664	67014.48
Jun-11	40695	66268.2
Jul-11	40725	66533.82
Aug-11	40756	68542.03
Sep-11	40787	69257.63
Oct-11	40817	68665.91
Nov-11	40848	69957.76
Dec-11	40878	71135.29
Jan-12	40909	71701.02
Feb-12	40940	76261.88
Mar-12	40969	75340.37
Apr-12	41000	72883.31
May-12	41030	69908.78
Jun-12	41061	69752.69
Jul-12	41091	68280.9
Aug-12	41122	68068.43
Sep-12	41153	72524.36
Oct-12	41183	75124.05
Nov-12	41214	72140.78
Dec-12	41244	76028.66
Jan-13	41275	74125.66
Feb-13	41306	77122.7
Mar-13	41334	77604.68
Apr-13	41365	72608.99
May-13	41395	71209.74
Jun-13	41426	71013.41
Jul-13	41456	71125.41
Aug-13	41487	72240.15
Sep-13	41518	72990.94
Oct-13	41548	75141.52
Nov-13	41579	76840.84
Dec-13	41609	78982.91
Jan-14	41640	83296.48
Feb-14	41671	84958.73
Mar-14	41699	80206.9
Apr-14	41730	77717.53
May-14	41760	73432.3
Jun-14	41791	72791.24
Jul-14	41821	71846.56
Aug-14	41852	71416.87
Sep-14	41883	73214.01

Oct-14	41913	78103.96		Dec-15	42339	79063
Nov-14	41944	75223.55		Jan-16	42370	78345
Dec-14	41974	76099.63		Feb-16	42401	82587
Jan-15	42005	85391		Mar-16	42430	80064
Feb-15	42036	83968		Apr-16	42461	81397
Mar-15	42064	81207		May-16	42491	72541
Apr-15	42095	77299		Jun-16	42522	72856
May-15	42125	72322		Jul-16	42552	71603
Jun-15	42156	72300		Aug-16	42583	72684
Jul-15	42186	70555		Sep-16	42614	73461
Aug-15	42217	71322		Oct-16	42644	79775
Sep-15	42248	79134		Nov-16	42675	77988
Oct-15	42278	79137		Dec-16	42705	77860
Nov-15	42309	78184				

## ANEXO 2 – PLD (Preço de Liquidação das Diferenças) R\$/MWh

MêsAno	SE/CO (R\$/MWh)	S (R\$/MWh)	NE (R\$/MWh)	N (R\$/MWh)	Média (SIN) (R\$/MWh)
May-03	7.30	7.30	6.34	6.23	6.79
Jun-03	11.22	11.22	10.53	10.43	10.85
Jul-03	13.13	11.22	10.53	10.43	11.33
Aug-03	16.95	18.56	13.37	16.89	16.44
Sep-03	18.30	20.52	15.44	18.30	18.14
Oct-03	25.82	26.30	19.88	25.73	24.43
Nov-03	28.03	29.85	24.70	27.91	27.62
Dec-03	20.18	20.18	49.41	19.93	27.43
Jan-04	23.68	23.68	294.09	21.48	90.73
Feb-04	18.59	18.59	18.59	18.59	18.59
Mar-04	18.59	18.59	18.59	18.59	18.59
Apr-04	18.59	18.59	18.59	18.59	18.59
May-04	18.59	18.59	18.59	18.59	18.59
Jun-04	18.59	18.59	18.59	18.59	18.59
Jul-04	18.59	18.59	18.59	18.59	18.59
Aug-04	18.59	18.59	18.59	18.59	18.59
Sep-04	18.59	18.59	18.59	18.59	18.59
Oct-04	18.75	18.75	18.59	18.75	18.71
Nov-04	18.59	18.59	18.59	18.59	18.59
Dec-04	18.59	18.59	18.59	18.59	18.59
Jan-05	18.33	18.33	18.33	18.33	18.33
Feb-05	18.33	18.99	18.33	18.33	18.50
Mar-05	18.33	26.78	18.33	18.33	20.44
Apr-05	24.88	83.97	18.33	18.87	36.51
May-05	43.96	79.35	18.33	20.28	40.48
Jun-05	26.45	24.07	18.33	25.42	23.57
Jul-05	31.74	31.56	18.33	31.74	28.34



Aug-05	34.51	34.51	18.50	34.51	30.51
Sep-05	31.94	29.42	18.40	31.94	27.93
Oct-05	43.12	18.33	18.86	43.12	30.86
Nov-05	35.73	24.17	19.79	35.73	28.86
Dec-05	19.20	19.19	18.40	19.20	19.00
Jan-06	28.64	28.78	19.14	19.14	23.93
Feb-06	58.02	63.63	37.62	29.20	47.12
Mar-06	28.56	42.67	36.10	18.94	31.57
Apr-06	20.87	21.06	16.92	16.92	18.94
May-06	51.91	52.51	19.79	16.97	35.30
Jun-06	67.89	70.01	23.44	44.84	51.55
Jul-06	90.90	91.44	30.61	90.90	75.96
Aug-06	104.98	105.19	51.94	104.98	91.77
Sep-06	123.88	123.88	68.56	123.88	110.05
Oct-06	92.42	92.42	46.25	92.42	80.88
Nov-06	80.82	80.82	24.40	80.82	66.72
Dec-06	58.75	59.18	17.58	45.23	45.19
Jan-07	22.62	26.28	17.59	17.59	21.02
Feb-07	17.59	17.59	17.59	17.59	17.59
Mar-07	17.59	17.59	17.59	17.59	17.59
Apr-07	49.36	49.05	28.05	24.25	37.68
May-07	59.96	23.48	53.37	53.37	47.55
Jun-07	97.15	59.42	97.19	97.35	87.78
Jul-07	122.59	122.19	118.94	122.87	121.65
Aug-07	39.27	36.13	45.81	44.36	41.39
Sep-07	149.53	149.80	149.11	149.53	149.49
Oct-07	198.13	198.13	197.45	198.13	197.96
Nov-07	185.11	185.11	185.11	185.11	185.11
Dec-07	204.93	204.93	204.93	204.93	204.93
Jan-08	502.45	502.45	497.61	502.45	501.24
Feb-08	200.42	200.65	214.65	200.43	204.04
Mar-08	124.70	127.41	123.24	117.67	123.26
Apr-08	68.80	72.12	71.92	50.97	65.95
May-08	34.18	34.19	34.42	27.61	32.60
Jun-08	76.20	76.20	75.34	75.34	75.77
Jul-08	108.42	108.42	108.42	108.42	108.42
Aug-08	102.79	101.21	102.79	102.79	102.40
Sep-08	109.93	109.40	109.91	109.93	109.79
Oct-08	92.43	92.17	92.43	92.43	92.37
Nov-08	106.14	93.77	106.14	106.14	103.05
Dec-08	96.97	96.93	96.97	96.97	96.96
Jan-09	83.64	83.66	77.77	77.82	80.72
Feb-09	52.08	66.15	27.41	27.41	43.26
Mar-09	90.87	91.28	84.25	24.96	72.84
Apr-09	46.46	48.73	27.79	16.31	34.82
May-09	39.00	39.10	30.17	16.31	31.15
Jun-09	40.89	40.84	30.00	23.14	33.72

Jul-09	30.43	30.43	25.55	25.55	27.99
Aug-09	16.31	16.31	16.31	16.31	16.31
Sep-09	16.31	16.31	16.31	16.31	16.31
Oct-09	16.31	16.31	16.31	16.31	16.31
Nov-09	16.31	16.31	16.31	16.31	16.31
Dec-09	16.31	16.31	16.31	16.31	16.31
Jan-10	12.91	12.91	12.91	12.91	12.91
Feb-10	13.82	13.82	15.91	13.82	14.34
Mar-10	27.24	27.24	30.38	27.24	28.03
Apr-10	21.47	21.47	24.62	21.46	22.26
May-10	32.34	30.10	33.99	32.35	32.20
Jun-10	67.70	67.70	69.40	69.40	68.55
Jul-10	89.61	89.61	97.56	97.56	93.59
Aug-10	116.66	116.66	123.56	123.55	120.11
Sep-10	132.10	131.78	189.37	189.37	160.66
Oct-10	137.78	137.78	232.48	232.48	185.13
Nov-10	116.68	116.68	115.05	116.68	116.27
Dec-10	71.62	71.62	68.69	71.62	70.89
Jan-11	28.19	28.19	28.96	28.16	28.38
Feb-11	49.59	41.85	50.39	49.33	47.79
Mar-11	23.41	20.95	24.91	23.31	23.15
Apr-11	12.20	12.20	12.20	12.20	12.20
May-11	17.35	17.35	17.24	17.24	17.30
Jun-11	31.80	31.80	31.75	31.75	31.78
Jul-11	23.08	22.66	23.13	23.13	23.00
Aug-11	19.61	15.92	19.62	19.62	18.69
Sep-11	21.18	16.98	21.18	21.18	20.13
Oct-11	37.14	37.04	37.14	37.14	37.12
Nov-11	45.55	45.55	45.55	45.55	45.55
Dec-11	44.47	44.47	37.37	37.37	40.92
Jan-12	23.14	23.14	12.92	12.92	18.03
Feb-12	50.67	50.67	12.57	12.57	31.62
Mar-12	124.97	124.97	109.12	109.12	117.05
Apr-12	192.70	195.75	182.68	182.68	188.45
May-12	180.94	180.94	180.37	180.37	180.66
Jun-12	118.49	118.49	118.65	118.49	118.53
Jul-12	91.24	91.24	91.24	91.24	91.24
Aug-12	119.08	119.05	119.08	119.08	119.07
Sep-12	182.94	182.94	183.30	183.30	183.12
Oct-12	280.39	280.39	294.82	294.82	287.61
Nov-12	375.54	375.54	375.54	375.54	375.54
Dec-12	259.57	259.57	253.24	253.24	256.41
Jan-13	413.95	413.95	409.76	409.76	411.86
Feb-13	214.54	214.54	212.59	212.59	213.57
Mar-13	339.75	339.75	339.84	339.40	339.69
Apr-13	196.13	196.13	197.38	196.13	196.44
May-13	344.84	344.84	344.94	344.84	344.87

Jun-13	207.62	204.10	207.94	207.67	206.83
Jul-13	121.29	102.59	121.61	121.35	116.71
Aug-13	163.38	145.56	164.69	163.38	159.25
Sep-13	266.16	248.36	269.10	269.10	263.18
Oct-13	260.99	213.92	270.23	262.48	251.91
Nov-13	331.07	331.07	331.07	331.07	331.07
Dec-13	290.72	290.72	291.86	290.72	291.01
Jan-14	378.22	378.22	379.35	364.80	375.15
Feb-14	822.83	822.83	755.90	454.44	714.00
Mar-14	822.83	822.83	756.37	696.21	774.56
Apr-14	822.83	822.83	744.28	640.73	757.67
May-14	806.97	806.97	772.21	334.59	680.19
Jun-14	412.65	206.99	412.60	412.60	361.21
Jul-14	592.54	503.10	592.54	592.54	570.18
Aug-14	709.53	709.53	709.53	709.53	709.53
Sep-14	728.95	728.95	728.95	728.95	728.95
Oct-14	776.88	731.53	776.88	776.88	765.54
Nov-14	804.54	804.54	804.54	804.54	804.54
Dec-14	601.21	601.21	601.21	601.21	601.21
Jan-15	388.48	388.48	388.48	388.48	388.48
Feb-15	388.48	388.48	388.48	388.48	388.48
Mar-15	388.48	388.48	388.48	388.48	388.48
Apr-15	388.48	388.48	388.48	127.36	323.20
May-15	387.24	387.24	387.24	137.14	324.72
Jun-15	372.73	372.73	372.73	372.73	372.73
Jul-15	240.08	205.97	243.97	241.24	232.82
Aug-15	145.09	145.09	145.09	145.09	145.09
Sep-15	227.04	227.04	227.04	227.04	227.04
Oct-15	212.32	203.72	218.92	218.92	213.47
Nov-15	202.87	186.28	274.90	257.60	230.41
Dec-15	116.08	110.55	303.22	166.89	174.19
Jan-16	35.66	35.61	310.38	63.49	111.29
Feb-16	30.42	30.42	166.28	30.42	64.39
Mar-16	37.73	37.73	249.11	37.73	90.58
Apr-16	49.42	49.42	266.71	49.46	103.75
May-16	75.93	74.91	106.07	88.98	86.47
Jun-16	61.32	56.13	118.60	102.22	84.57
Jul-16	83.43	83.43	108.68	106.13	95.42
Aug-16	115.58	112.36	119.47	119.47	116.72
Sep-16	149.02	140.35	149.02	149.02	146.85
Oct-16	200.21	200.21	200.21	200.21	200.21
Nov-16	166.05	166.05	166.05	166.05	166.05
Dec-16	122.19	122.19	122.19	122.19	122.19