

Título: MANUAL DE METODOLOGIA E USO DO PREVCARGADESSEM 2.0**Nº de Páginas:** 31**Nº de Anexos:****Dados do Cliente:**

OPERADOR NACIONAL DO SISTEMA ELÉTRICO - ONS

Rua Júlio do Carmo, 251 - Cidade Nova

Rio de Janeiro - RJ, CEP: 20211-160

Responsável:

Debora Dias Jardim Penna

e-mail: debora.jardim@ons.org.br

Departamento: Departamento de Otimização Energética e Meio Ambiente

- DEA

Nº do PEP:**Centro de Lucro:** C230000101**Centro de Custo:** C203000013**Resumo:**

O presente relatório descreve a metodologia de previsão de carga implementada no PrevcargaDESSEM 2.0, apresenta os dados necessários para o cálculo da previsão e fornece informações para a execução do modelo em ambiente R.

Observações:**Autores:**

José Francisco Moreira Pessanha - Cepel

Victor Andrade De Almeida - Cepel

Gabriel Augusto Gonçalves - ONS

Maria Helena Teles De Azevedo - ONS

Danilo Lopes Do Carmo - ONS

Evandro Luiz Mendes - ONS

Fernando Cesar Cunha Bouissa - ONS

Palavras-Chave:

Previsão de carga

Séries temporais

DESSEM

Classificação de acesso:☐ Público ☐ Interno ☒ Setorial ☐ Confidencial**Aprovação e data de emissão****André Luiz Diniz Souto Lima****Chefe do Departamento de Otimização Energética e Meio Ambiente****Tel.:** 21-2598-6046**E-mail:** diniz@cepel.br**Aprovação e data de emissão****Maurício Barreto Lisboa****Diretor de Pesquisa, Desenvolvimento e Inovação**

Sumário

SUMÁRIO EXECUTIVO	3
1. INTRODUÇÃO	4
2. MÉTODOS DE PREVISÃO USADOS NO PREVCARGADESSEM 2.0	5
2.1 Introdução	5
2.2 Regressão linear múltipla	5
2.3 Regressão dinâmica	6
2.4 Redes Neurais Artificiais - RNA	6
2.5 Máquinas de vetor de suporte para regressão - SVM	11
3. MODELAGEM DA PREVISÃO DE CARGA NO PREVCARGADESSEM.....	15
3.1 Introdução	15
3.2 Modelos de previsão de carga para os dias normais.....	15
3.2.1 Modelo de previsão da demanda média diária em dias normais.....	15
3.2.2 Modelo de previsão do perfil de carga para um dia normal	16
3.3 Modelo de previsão para dias de feriado/dias especiais	17
3.3.1 Modelo de previsão da demanda média diária em dias de feriado/dias especiais.....	17
3.3.2 Modelo SVM para previsão do perfil de carga para um dia de feriado/dia especial	18
3.3.3 Modelo de regressão linear para previsão do perfil de carga em feriados/dia especial.....	19
3.4 Previsão combinada	21
4. PROGRAMA PREVCARGADESSEM 2.0	22
4.1 Instalação.....	22
4.2 Arquivos de dados.....	23
4.2.1 Histórico da carga global em base horária	23
4.2.2 Pesos das previsões no cálculo da previsão combinada.....	24
4.2.3 Lista de feriados e dias especiais	24
4.2.4 Histórico das temperaturas horárias	25
4.2.5 Previsão das temperaturas horárias.....	25
4.2.6 Intervalos de duração dos patamares de carga.....	26
5. EXECUÇÃO EM AMBIENTE R.....	26
REFERÊNCIAS BIBLIOGRÁFICAS.....	30

Sumário Executivo

O presente relatório descreve a metodologia e o uso do programa PrevcargaDESSEM 2.0, uma nova versão do programa PrevcargaDESSEM resultante dos aprimoramentos realizados ao longo do ano de 2021.

Motivação: Os efeitos da pandemia de Covid 19 sobre as atividades econômicas e hábitos cotidianos afetaram o comportamento da demanda por energia elétrica. As mudanças observadas no nível e no perfil da carga apontaram para a necessidade de revisar as estratégias de previsão de carga implementadas no PrevcargaDESSEM.

Objetivos: A revisão do PrevcargaDESSEM teve como objetivos o aumento da acurácia das previsões de carga, a paralelização da execução da previsão de carga e a modularização do código para facilitar a sua manutenção, bem como permitir a inserção de novos modelos de previsão de carga.

Metodologia: A metodologia de previsão de carga do PrevcargaDESSEM 2.0 preserva os modelos baseados em máquinas de vetor de suporte e redes neurais artificiais consideradas na versão anterior, porém introduz modificações no conjunto de variáveis explicativas e na seleção dos padrões que formam o conjunto de treinamento dos modelos. As rotinas de tratamento de dados foram retiradas, pois o ONS já fornece os dados tratados. Os modelos de regressão quantílica e de programação quadrática usados na correção das previsões também foram retirados, dado que não melhoraram a performance do previsor. Um modelo de regressão dinâmica foi inserido com o objetivo de prever a demanda média diária e um modelo de regressão linear múltipla substituiu o modelo baseado em lógica *fuzzy* que era utilizado na previsão dos perfis de carga dos dias especiais e feriados. Em termos de implementação computacional, a execução da previsão foi paralelizada e o código foi modularizado para permitir a inserção de novos modelos de previsão de carga. Adicionalmente, em virtude do fim do horário de verão, a entrada de dados do programa foi simplificada.

Resultados: As modificações implementadas aumentaram a acurácia das previsões, sobretudo nos feriados e dias especiais, a paralelização agilizou a execução das previsões e a reestruturação do código melhorou as condições para manutenção e evolução do programa.

1. Introdução

As medidas de isolamento social para enfrentamento da pandemia de Covid 19, iniciadas em março de 2020, restringiram o desenvolvimento das atividades econômicas, mudaram os hábitos de consumo da população e, consequentemente, afetaram o comportamento da carga. Diante das mudanças observadas na carga, o ONS e o Cepel iniciaram uma revisão profunda do programa de previsão de carga PrevcargaDESSEM com o objetivo de aumentar a acurácia das previsões de carga, prejudicada pelos efeitos decorrentes da pandemia. A revisão do programa foi organizada em duas etapas, sendo que na primeira etapa, finalizada em dezembro de 2021, foram implementadas as modificações listadas na Tabela 1.

Tabela 1 – Modificações realizadas no PrevcargaDESSEM

1	Remoção da rotina de tratamento de dados de carga e temperatura, dado que o tratamento de dados passou a ser realizado pelo ONS.
2	Remoção da correção da previsão por regressão quantílica.
3	Remoção do ajuste de previsão por programação quadrática.
4	Extensão do horizonte de previsão para 10 dias à frente.
5	Substituição do modelo de previsão por similaridade para feriados e dias especiais por um modelo de regressão linear múltipla.
6	Introdução de valores passados da temperatura como variáveis explicativas nos modelos de previsão da demanda média diária.
7	Introdução da demanda da hora imediatamente anterior ao horário da previsão nos modelos de máquinas de vetor de suporte usados na previsão do perfil de carga.
8	Reestruturação e modularização do código para facilitar a inserção de novos modelos (modelos <i>plug-in</i>) e paralelização do código para acelerar a execução das previsões.

O programa PrevcargaDESSEM 2.0, resultante das modificações implementadas na primeira fase da revisão, produziu previsões de carga que alcançaram um nível de acurácia superior à obtida pela versão 1.26.8, última versão anterior à revisão do programa.

O presente relatório técnico tem por objetivo descrever a metodologia de previsão de carga adotada no PrevcargaDESSEM 2.0, bem como fornecer instruções básicas para a sua utilização e visualização dos resultados obtidos. O relatório está organizado em cinco seções. Na seção 2 apresentam-se as noções básicas dos métodos de previsão utilizados no PrevcargaDESSEM 2.0, enquanto a aplicação de cada modelo na estratégia de previsão é ilustrada na seção 3. Os dados necessários para a execução do programa são descritos na seção 4. Finalmente, na seção 5 são fornecidas orientações para o uso do programa e visualização dos resultados.

2. Métodos de previsão usados no PrecvargaDESSEM 2.0

2.1 Introdução

O PrecvargaDESSEM 2.0 baseia-se em algoritmos estatísticos e de aprendizagem de máquina, entre os quais destacam-se a regressão linear múltipla, a regressão dinâmica, as Redes Neurais Artificiais – RNA e as Máquinas de Vetor de Suporte – SVM para regressão. Nesta seção serão introduzidas algumas noções básicas dos métodos supracitados.

2.2 Regressão linear múltipla

Na previsão de carga busca-se uma função que permita estimar o valor da carga em um instante t , a variável resposta y_t , em função de um conjunto de variáveis explicativas, x_t , que incluem dados conhecidos do instante t , por exemplo, a temperatura prevista, o dia da semana e mês, se dia normal ou feriado e dados passados da própria carga. Sem perda de generalidade, o modelo de regressão linear assume que a variável resposta seja uma função linear de k variáveis explicativas (HONG *et al.*, 2010):

$$y_t = \beta_0 + \beta_1 x_{t,1} + \beta_2 x_{t,2} + \dots + \beta_k x_{t,k} + \varepsilon_t \quad (1)$$

em que $\beta_0, \beta_1, \dots, \beta_k$ denotam os coeficientes de regressão a serem estimados e ε_t denota o erro do modelo de regressão, i.e., um termo aleatório que representa o efeito de fatores não observáveis sobre a carga.

Adicionalmente, o modelo assume que o termo aleatório ε_t é um ruído branco, i.e., satisfaz as seguintes propriedades:

$$E(\varepsilon_t) = 0 \quad (2)$$

$$V(\varepsilon_t) = \sigma_\varepsilon^2 = \text{constante} \quad (3)$$

$$E(\varepsilon_s \varepsilon_t) = 0 \quad \forall s \neq t \quad (4)$$

A estimação dos coeficientes de regressão (β) requer uma amostra com n observações da variável resposta ($y_t \quad \forall t = 1, n$), acompanhadas das respectivas observações nas k variáveis explicativas ($x_{t,1}, x_{t,2}, \dots, x_{t,k} \quad \forall t = 1, n$). Os valores observados $y_t \quad \forall t = 1, n$ podem ser dispostos em um vetor Y e as observações das variáveis explicativas podem ser dispostas em uma matriz X , conforme indicado a seguir:

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & & x_{2k} \\ \vdots & & & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix} \quad (5)$$

em que a primeira coluna da matriz X está associado com o coeficiente β_0 .

A partir das matrizes X e Y faz-se a estimação dos coeficientes de regressão pelo método dos mínimos quadrados ordinários:

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad (6)$$

Assim, a previsão da variável resposta é dada por:

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_{t,1} + \hat{\beta}_2 x_{t,2} + \dots + \hat{\beta}_k x_{t,k} \quad (7)$$

2.3 Regressão dinâmica

De forma distinta dos modelos de regressão linear múltipla, nos modelos de regressão dinâmica o termo aleatório ε_t pode ser autocorrelacionado e ter seu processo estocástico subjacente descrito por um modelo ARIMA(p,d,q). Assim, o modelo de regressão dinâmica passa a ter a seguinte especificação (HYNDMAN & ATHANASOPOULOS, 2021):

$$y_t = \beta_0 + \beta_1 x_{t,1} + \beta_2 x_{t,2} + \dots + \beta_k x_{t,k} + \eta_t \quad (8)$$

$$(1 - \phi B)^p (1 - B)^d \eta_t = (1 - \theta B)^q \varepsilon_t \quad (9)$$

Note que o modelo acima tem dois termos aleatórios, o erro η_t na equação de regressão (8) e o ruído branco ε_t na equação (9) do modelo ARIMA de η_t .

Em função da autocorrelação nos erros, a estimação dos parâmetros do modelo é realizada por máxima verossimilhança. Adicionalmente, vale ressaltar que a variável resposta e as variáveis explicativas devem ser séries temporais estacionárias, caso contrário as séries devem ser previamente diferenciadas. Neste caso o modelo de regressão dinâmica passa a ser:

$$y'_t = \beta_0 + \beta_1 x'_{t,1} + \beta_2 x'_{t,2} + \dots + \beta_k x'_{t,k} + \eta'_t \quad (10)$$

$$(1 - \phi B)^p \eta'_t = (1 - \theta B)^q \varepsilon_t \quad (11)$$

em que

$$y'_t = (1 - B)^d y_t \quad (12)$$

$$x'_{t,i} = (1 - B)^d x_{t,i} \forall i = 1, k \quad (13)$$

2.4 Redes Neurais Artificiais - RNA

O cérebro humano é composto por cerca de 100 bilhões de células nervosas, conhecidas por neurônios, que se conectam massivamente umas às outras através de ligações eletroquímicas, denominadas sinapses, formando uma grande rede de processamento. Cada neurônio recebe estímulos através dos dendritos, os processa em seu corpo celular e, dependendo do seu estado de ativação, gera e transmite um estímulo pelo seu axônio para que atinja outros neurônios. A estrutura e o funcionamento do neurônio biológico podem ser modelados pelo neurônio artificial ilustrado na Figura 1.




Figura 1. Neurônio artificial de McCulloch & Pitts (KOVÁCS, 1996).

No neurônio artificial os N terminais de entrada representam os dendritos e o único terminal de saída representa o axônio. A intensidade das sinapses é representada pelos pesos (w) nos terminais de entrada, cujos valores podem ser

negativos ou positivos, definindo sinapses inibidoras ou estimuladoras respectivamente. De forma análoga ao que acontece no cérebro humano, onde as sinapses são reforçadas ou enfraquecidas, os pesos são ajustados durante a evolução do processo de aprendizagem da rede.

O comportamento do corpo celular é emulado por um mecanismo que faz a soma ponderada dos valores recebidos (cálculo do *net*). No modelo mais simples, esta soma ponderada é comparada com um limiar θ . Neste modelo, a função de ativação que relaciona a resposta do neurônio com a soma ponderada dos valores recebidos é uma função degrau: se $x_1 w_1 + x_2 w_2 + \dots + x_N w_N \geq \theta$ o neurônio é ativado e produz uma saída igual a 1, caso contrário o neurônio não dispara e a saída é zero. Enfim, o corpo celular é responsável pelo mapeamento dos sinais de entrada em um único sinal de saída. No lugar da função degrau pode-se usar funções contínuas, por exemplo, a funções sigmoide.

As RNA são sistemas paralelos distribuídos, compostos por unidades de processamento simples (neurônios) dispostas em uma ou mais camadas que são interligadas por muitas conexões geralmente unidirecionais e com pesos para ponderar a entrada recebida por cada neurônio. Através de uma analogia com o cérebro humano, pode-se afirmar que os pesos das conexões armazenam o conhecimento ou a memória da rede neural.

A organização de vários neurônios artificiais em uma estrutura e a forma de como eles se interligam definem a arquitetura de uma RNA. A arquitetura mais usual é a rede *perceptron* de múltiplas camadas ou *Multilayer Perceptron* (MLP) com três camadas, conforme mostra a Figura 2.




Figura 2. Rede MLP com três camadas.

A primeira camada da rede é a camada de entrada, sendo a única camada exposta aos sinais externos. Esta camada transmite os sinais recebidos para os neurônios da próxima camada, conhecida como camada escondida. Os neurônios das camadas escondidas extraem as características relevantes ou padrões dos sinais de entrada e transmitem o resultado para a camada de saída, a última camada da rede. A definição da arquitetura envolve a definição dos seguintes parâmetros: número de camadas escondidas, número de neurônios em cada camada e o tipo de conexão entre os neurônios.

A definição do número de camadas escondidas e do número de neurônios em cada camada é feita de forma empírica e depende da distribuição dos padrões de entrada, quantidade de ruído presente nos exemplos de treinamento e da complexidade da função a ser aprendida (HAYKIN, 2009).

O ajuste dos pesos sinápticos é realizado por meio de um processo iterativo denominado aprendizagem. O aprendizado pode acontecer, basicamente, de duas formas distintas: supervisionado e não supervisionado. O primeiro é comum em previsão de séries temporais, enquanto o segundo é utilizado para realizar análise de agrupamentos.

O aprendizado supervisionado consiste em apresentar padrões de entrada e saída desejada à RNA. Quando a saída gerada pela rede, a partir dos cálculos efetuados com o padrão de entrada e os pesos correntes, difere da saída desejada, os pesos são ajustados de forma a reduzir o erro. Essa dinâmica é repetida por todo conjunto de padrões (pares entradas e saídas) inúmeras vezes, até que a taxa de erro esteja dentro de uma faixa considerada satisfatória.

O método de treinamento mais usado no treinamento supervisionado é a retropropagação do erro ou *error backpropagation* (WERBOS, 1990), um algoritmo que utiliza pares (entrada, saída desejada) para através de um mecanismo de correção de erro ajustar os pesos da rede.

O ajuste dos pesos se dá pela execução de um processo de otimização realizado em duas fases: fase *forward* e fase *backward*, conforme ilustrado na Figura 3, onde os pesos são definidos de forma a minimizar a soma dos quadrados dos erros:

$$E = \frac{1}{2} \sum_p \sum_{j=1}^n (d_j^p - y_j^p)^2 \quad (14)$$

em que p é o número de padrões de treinamento (padrões de entrada e saída), n é o número de neurônios da camada de saída, d_j é a saída desejada para o j -ésimo neurônio da camada de saída, y_j é o resultado gerado pelo j -ésimo neurônio da camada de saída.




Figura 3. Fases *forward* e *backward* do algoritmo de retropropagação do erro.

Na fase *forward* a rede é apresentada à um padrão de entrada e gera uma saída. Na fase *backward* a diferença (erro) entre a saída desejada e a saída gerada pela rede é utilizada para ajustar os pesos das sinapses. Para minimizar a soma dos quadrados dos erros o algoritmo de aprendizagem se baseia no método do gradiente descendente, por isso, a fim de que esse método seja utilizado a função de ativação precisa ser contínua, diferenciável e não decrescente, por exemplo, a função sigmoide. O algoritmo *error backpropagation* pode ser resumido nas seguintes operações (HAYKIN, 2009):

1º Passo - Inicialize aleatoriamente os pesos da rede e faça o contador de épocas (t) igual a zero.

2º Passo - Apresente uma época de exemplos de treinamento à rede. Uma época indica o número de vezes que os padrões de entrada (x) e o respectivo padrão de saída (y^d) (padrões do conjunto de treinamento) são apresentados à rede. Para cada exemplo de treinamento realizar os passos 3 e 4 a seguir.

3º Passo – Fase forward: Propague o padrão de entrada (X_p) para frente, camada por camada, até chegar na camada de saída. Para cada neurônio calcule a combinação dos sinais recebidos da camada anterior:

$$net_j^l(t) = \sum_{i=0}^m w_{j,i}^l(t) \cdot y_i^{l-1}(t) \quad (15)$$

em que $y_i^{l-1}(t)$ é a saída produzida pelo neurônio i da camada anterior $l-1$ e $w_{j,i}^l(t)$ é o peso sináptico da conexão do neurônio j na camada l com o neurônio i da camada anterior $l-1$.

Para $i=0$ tem-se o viés (bias) aplicado ao neurônio j na camada l : $y_0^{l-1}(t) = 1$ e $w_{j,0}^l(t) = b_j^l(t)$.

Se o neurônio j está na primeira camada oculta, i.e., $l=1$ $y_i^0(t) = x_i(t)$.

Denotando por f_j a função de ativação do neurônio j , o sinal produzido por ele é:

$$y_j^l(t) = f_j(net_j^l(t)) \quad (16)$$

No final calcule o erro, ou seja, a diferença entre a resposta desejada e a resposta fornecida pela rede:

$$e_j(t) = y_j^d - y_j \quad (17)$$

4º Passo – Fase backward: Propague o erro calculado no passo 3 para trás, começando na camada de saída e terminando na camada de entrada. Neste processo ajuste os pesos da seguinte forma:

$$w_{j,i}^l(t+1) = w_{j,i}^l(t) + \eta \delta_j^l(t) y_i^{l-1}(t) \quad (18)$$

em que η é a taxa de aprendizagem, $y_i^{l-1}(t)$ é a resposta do neurônio i situado na camada anterior $l-1$ e $\delta_j^l(t)$ é o gradiente local do neurônio j da camada l , definido de acordo com a localização do neurônio na rede.

Se a camada l onde está o neurônio é uma camada de saída tem-se:

$$\delta_j^l(t) = e_j(t) \cdot \frac{df_j(net_j^l(t))}{dnet_j} \quad (19)$$

Porém, se a camada l onde o neurônio estiver é uma camada escondida, o seu gradiente local é:

$$\delta_j^l(t) = \frac{df_j(net_j^l(t))}{dnet_j} \cdot \sum_{k=1}^m \delta_k^{l+1}(t) \cdot w_{kj}^{l+1}(t) \quad (20)$$

em que m é número de neurônios da camada $l+1$, $\delta_k^{l+1}(t)$ é o gradiente local do neurônio k situado na camada $l+1$ e $w_{kj}^{l+1}(t)$ é o peso sináptico da conexão entre o neurônio j na camada l e o neurônio k na camada $l+1$

5º Passo – Após terminar uma época de exemplos faça $t=t+1$ e itere para frente e para trás os passos 3 e 4. Pare apenas quando o critério de parada¹ for satisfeito.

A construção de um modelo baseado em rede neural artificial envolve a busca da melhor configuração para a rede, i.e., a definição do número adequado de camadas escondidas e a definição da quantidade ideal de processadores nestas camadas. A inexistência de regras que definam claramente a configuração adequada faz desta busca um processo empírico que demanda um longo tempo de processamento, em que diferentes configurações devem ser avaliadas. Entretanto, deve-se sempre empregar o princípio da parcimônia, e saber que uma rede com apenas uma camada oculta é capaz de aproximar qualquer tipo de função contínua (HAYKIN, 2009), embora em algumas situações específicas sejam usadas duas camadas.

Embora não existam leis que definam a configuração ótima, existem algumas propriedades que regem a convergência do algoritmo de treinamento, bem como a capacidade de generalização das RNA. O conhecimento destas propriedades orienta o processo de busca da configuração ótima e permite obter melhores resultados.

Em uma rede neural pequena há dificuldade de armazenar todos os padrões necessários e por isso a convergência do algoritmo de treinamento é mais lenta. Em uma rede pequena os processadores ficam sobrecarregados e lidam com muitas restrições na tentativa de encontrar uma representação ótima. Porém, deve-se ter o cuidado de não utilizar processadores demais, pois a rede pode memorizar os padrões de treinamento, ao invés de extrair as características gerais que permitirão o reconhecimento de padrões não vistos durante o treinamento.

Com relação às redes com mais de uma camada escondida é importante observar que cada vez que o erro é propagado para a camada anterior, ele se torna menos útil e preciso. Apenas a camada imediatamente anterior à camada de saída tem uma noção precisa do erro, todas as camadas escondidas anteriores recebem um valor impreciso do erro. Por esta razão a convergência dos pesos destas camadas é mais lenta.

No método *error backpropagation*, o peso sináptico i do elemento processador j é atualizado de acordo com a seguinte regra entre as iterações t e $t+1$:

$$w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij} \quad (21)$$

em que

$$\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}} = -(\text{taxa de aprendizado}) \times \text{derivado do erro em relação a } w_{ij} \quad (22)$$

O *error backpropagation* é inspirado no método do gradiente descendente: dado um ponto w no espaço dos pesos sinápticos, a taxa de aprendizagem η controla o tamanho do passo na direção oposta ao gradiente, a ser dado a partir deste ponto, visando minimizar o erro. Desta forma, um valor pequeno para η resulta em uma convergência lenta, enquanto um valor de maior magnitude para η acelera a convergência do treinamento, seja em redes com apenas uma camada escondida, ou em redes mais complexas, como a rede com duas camadas escondidas.

¹ Usualmente o critério de parada fixa um determinado número de iterações ou estabelece uma tolerância para o erro.

Entretanto, a taxa de aprendizagem não deve ser nem muito pequena e nem muito grande, pois com uma taxa pequena pode-se ficar preso em um mínimo local e a rede neural não conseguir aprender com a precisão especificada, por outro lado, valores grandes para a taxa de aprendizado tornam o treinamento instável, com fortes oscilações nos pesos de uma iteração para outra e o algoritmo de treinamento pode não convergir. Para acelerar o treinamento, porém evitando a instabilidade no ajuste dos pesos, adiciona-se o termo momento (α) no incremento dos pesos a cada iteração:

$$\Delta w_{ij}(t+1) = -\eta \frac{\delta E}{\delta w_{ij}} + \alpha \Delta w_{ij}(t) \quad (23)$$

Nas regiões em que o gradiente aponta no mesmo sentido, a consideração do termo momento reforça o sinal dado pelo gradiente e acelera o treinamento, por sua vez, nas regiões em que o gradiente muda de direção, o termo momento suprime a oscilação nos pesos.

A previsão de valores futuros de uma série temporal, por meio de uma RNA (WERBOS, 1990, ZHANG et al, 1998), inicia-se com a montagem do conjunto de treinamento, que depende da definição do tamanho da janela de tempo para os valores passados das variáveis explicativas e do horizonte de previsão.

O padrão de entrada é formado pelos valores passados das variáveis explicativas e a saída desejada é o valor da observação da série temporal no horizonte de previsão. A Figura 4 ilustra como deve ser construído o conjunto de treinamento no caso da previsão um a passo à frente basear-se nos quatro últimos valores passados. A construção dos padrões de treinamento da rede consiste em mover as janelas de entrada e saída ao longo de toda série temporal. Cada par de janelas entrada/saída funciona como um padrão de treinamento e deve ser apresentado repetidas vezes até que o algoritmo de aprendizado alcance a convergência.




Figura 4. Montagem do conjunto de treinamento.


2.5 Máquinas de vetor de suporte para regressão - SVM

Proposta por Vapnik (1992), o algoritmo denominado Máquinas de Vetor de Suporte - SVM pode ser usado tanto em problemas de classificação de padrões quanto em problemas de regressão (SMOLA & SCHOLKOPF, 2004), neste último caso denomina-se Regressão por Vetores de Suporte (*Support Vector Regression – SVR*).


Considere uma série temporal com n observações de carga $y_i \forall i=1,n$ acompanhadas das respectivas variáveis explicativas representadas pelo vetor $X_i \forall i=1,n$. A previsão de carga pode ser efetuada pelo ajuste do seguinte modelo de regressão:

$$f(X) = w^T X + b \quad (24)$$

Conforme ilustrado na Figura 5a, a equação de regressão em (24) pode ser tratada como um hiperplano no centro de um hipertubo (*hypertube*) de largura 2ε com $\varepsilon > 0$ que envolve todas as observações.



(a) Hipertubo e hiperplano de regressão



(b) Variáveis de folga ξ

Figura 5. Hipertubo, hiperplano de regressão e variáveis de folga.

A melhor forma de alinhar o hipertubo aos dados consiste em posicioná-lo de maneira que as observações fiquem próximas da sua parede. Apesar do alinhamento ótimo do hipertubo aos dados não ser efetuado pelo método dos mínimos quadrados ordinários, o seu posicionamento é determinado pela solução do seguinte problema de programação quadrática:

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2} w^T w \\ & y_i - (w^T X_i + b) \leq \varepsilon \\ & (w^T X_i + b) - y_i \leq \varepsilon \end{aligned} \quad (25)$$

Contudo, não se pode garantir que todos os dados estejam dispostos dentro de um hipertubo de largura 2ε . Para acomodar estas situações o modelo em (25) deve ser modificado com a adição de variáveis de folga ξ indicadas no modelo em (26). Geometricamente, as variáveis de folga representam os desvios entre as paredes do hipertubo e as observações exteriores ao hipertubo, conforme indicado na Fig. 5b.

$$\begin{aligned} \min_{w, b, \xi^-, \xi^+} \quad & \frac{1}{2} w^T w + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) \\ & y_i - (w^T X_i + b) \leq \xi_i^+ + \varepsilon \\ & (w^T X_i + b) - y_i \leq \xi_i^- + \varepsilon \\ & \xi_i^-, \xi_i^+ \geq 0 \end{aligned} \quad (26)$$

No problema de otimização em (26) a constante C é positiva e permite controlar o *trade-off* entre a maximização da margem e a minimização das variáveis de folga, um mecanismo de prevenção ao sobreajuste (*overfitting*). A solução do problema de otimização em (26) na sua forma dual em (27) é mais simples de ser alcançada (HAMEL, 2009).

$$\begin{aligned} \max_{\lambda_i^+, \lambda_i^-} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\lambda_i^+ - \lambda_i^-)(\lambda_j^+ - \lambda_j^-) X_i^T X_j + \sum_{i=1}^n y_i (\lambda_i^+ - \lambda_i^-) - \varepsilon \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) \\ \text{s. a.} \quad & \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) = 0 \\ & 0 \leq \lambda_i^+, \lambda_i^- \leq C \end{aligned} \quad (27)$$

em que λ denota os multiplicadores de Lagrange associados com as restrições do problema de otimização em (26).

As relações entre as soluções dos problemas primal em (26) e dual em (27) são estabelecidas pelas equações (28) e (29) a seguir:

$$w = \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) X_i \quad (28)$$

$$b = \frac{1}{n} \sum_{i=1}^n w^T X_i - y_i \quad (29)$$

Substituindo a equação (28) em (24) tem-se a seguinte equação de previsão para uma entrada X :

$$f(X) = \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) X_i^T X + b \quad (30)$$

Uma vantagem do algoritmo SVR é a facilidade com que se pode estender o modelo de regressão linear no modelo de regressão não linear. A transformação da equação de previsão em (30) e do problema de programação matemática em (27) para o caso não linear consiste em substituir o produto $X_i^T X_j$ por uma função núcleo (*kernel trick*) que mapeia o espaço de entrada em um espaço de maior dimensão:

$$\Phi(X_i, X_j) = \phi(X_i) \phi(X_j) \quad (31)$$

O modelo de regressão resultante é ilustrado a seguir em (32). Na sequência, em (33) tem-se a equação de previsão para o caso não linear:

$$\begin{aligned} \text{Max}_{\lambda_i^+, \lambda_i^-} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\lambda_i^+ - \lambda_i^-) (\lambda_j^+ - \lambda_j^-) \Phi(X_i^T X_j) + \sum_{i=1}^n y_i (\lambda_i^+ - \lambda_i^-) - \varepsilon \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) \\ \text{s. a.} \quad & \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) = 0 \\ & 0 \leq \lambda_i^+, \lambda_i^- \leq C \eta_i \end{aligned} \quad (32)$$

$$f(X) = \sum_{i=1}^n (\lambda_i^+ - \lambda_i^-) \Phi(X_i^T X) + b \quad (33)$$

Os resultados de uma Máquina de Vetor de Suporte para regressão são sensíveis à definição dos seus hiperparâmetros, um conjunto formado pela constante C , pela largura do tubo ε e pela função núcleo (*kernel*).

A definição dos valores ótimos para os hiperparâmetros, em especial a constante C e a largura ε consiste em aplicar a validação cruzada ou *k-fold cross validation* (YADAV & SHUKLA, 2016).

A *K-fold cross validation* consiste em dividir aleatoriamente o conjunto de dados original em um número K de subconjuntos de mesmo tamanho. Com isso, o treinamento é realizado K vezes, utilizando a cada rodada um dos subconjuntos para validação e todos os outros para o treinamento do modelo. Para cada subconjunto de treinamento são calculadas métricas de desempenho para avaliar o erro de generalização e, ao final, de todas as rodadas de treinamento, é calculado o valor médio dos erros. Uma vantagem da validação cruzada é que o treinamento é realizado em todo o conjunto de dados, esperando-se assim uma maior capacidade de generalização do modelo. A Figura 6 ilustra o processo de validação cruzada *K-fold* para um $K=10$.

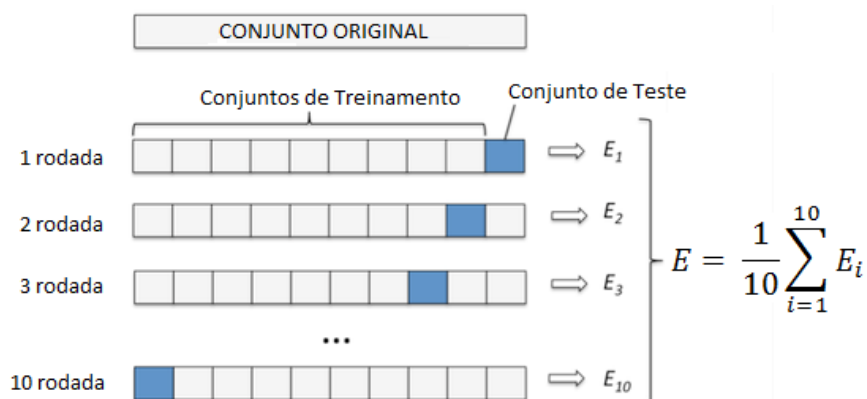


Figura 6. Exemplo de validação cruzada para K=10.

3. Modelagem da previsão de carga no PrecvargaDESSEM

3.1 Introdução

A demanda por energia elétrica em uma hora h em um dia d , $D(h,d)$, pode ser decomposta em duas parcelas e expressa da seguinte maneira:

$$D(h,d) = D(d) * D(h,d)/D(d) \quad \forall h=1,24 \quad (34)$$

em que $D(d)$ é a demanda média diária do dia d e $pu(h,d)=D(h,d)/D(d)$ é o perfil de carga normalizado pela demanda média.

Assim, a previsão para a demanda $D(h,d) \quad \forall h=1,24$ pode ser obtida por meio do produto de duas previsões: a previsão da demanda média diária (MW) e a previsão do perfil de carga (p.u. da demanda média), ambos para o dia d .

No PrecvargaDESSEM 2.0, a previsão da demanda média diária é determinada por uma rede neural artificial (RNA) ou por uma máquina de vetor de suporte (SVM) ou por um modelo de regressão dinâmica (RD). Já a previsão do perfil de carga, em base horária e em p.u. da demanda média diária, é determinada por máquinas de vetor de suporte ou por um modelo de regressão linear múltipla, no caso de o dia d ser um feriado ou dia especial. A previsão do perfil de carga horária em MW corresponde ao produto das duas previsões supracitadas.

O PrecvargaDESSEM 2.0 produz previsões de carga até 240 horas à frente com resolução temporal semi-horária e por patamar. As previsões de carga em base semi-horária são obtidas por meio de interpolação *spline* (DUBINSKY & ELPERIN, 1997) das previsões horárias, enquanto as previsões por patamar correspondem aos valores médios nos intervalos horários indicados na Tabela 2. Na sequência apresentam-se os modelos para previsão da demanda média diária e os modelos para previsão do perfil de carga em p.u. da demanda média diária.

Tabela 2 – Intervalos de duração dos patamares de carga.

Patamar de carga	maio a agosto		abril, setembro e outubro		novembro a março	
	2ª a 6ª feira	sábado, domingo e feriado	2ª a 6ª feira	sábado, domingo e feriado	2ª a 6ª feira	sábado, domingo e feriado
Leve	1ªh à 7ªh	1ªh à 18ªh 23ªh à 24ªh	1ªh à 8ªh	1ªh à 18ªh 23ªh à 24ªh	1ªh à 8ªh	1ªh à 19ªh 24ªh
Média	8ªh à 10ªh 23ªh à 24ªh	19ªh à 22ªh	9ªh à 10ªh 21ªh à 24ªh	19ªh à 22ªh	9ªh à 10ªh 19ªh à 24ªh	20ªh à 23ªh
Pesada	11ªh à 22ªh		11ªh à 20ªh		11ªh à 18ªh	

Fonte: Submódulo 4.4, Procedimentos de Rede – Módulo 4 – Programação da operação. consolidação da previsão de carga para a programação eletroenergética, Novembro, 2021.

3.2 Modelos de previsão de carga para os dias normais

3.2.1 Modelo de previsão da demanda média diária em dias normais

Se o dia d da previsão é um dia normal, o PrecvargaDESSEM 2.0 treina modelos SVM ou RNA ou ajusta um modelo de regressão dinâmica para a previsão da demanda média diária em MW, $\hat{D}(d)$.

Para o treinamento de modelos SVM ou RNA o programa oferece três alternativas: RNA (com dois neurônios em uma camada escondida), SVM com *kernel* linear e SVM com *kernel* radial. Neste caso, as variáveis de entrada incluem as demandas médias dos dias $d-1$, $d-2$ e $d-7$, acompanhadas pelas respectivas temperaturas, sendo que para a

temperatura o programa oferece quatro especificações possíveis: sem temperatura, média da temperatura diária, máxima temperatura diária e valores mínimo e máximo da temperatura diária. Portanto, totalizando 12 modelagens possíveis para a previsão da demanda média diária em um dia d normal.

O processo de formação do conjunto de padrões entrada/saída considerado no treinamento da máquina de vetor de suporte (SVM) e da rede neural artificial (RNA) tem duas etapas. Inicialmente, o conjunto é formado pelos padrões nas vizinhanças dos dias do histórico na mesma data dia/mês do dia d da previsão, conforme ilustrado na Figura 7, na qual observa-se que as vizinhanças abrangem um período de até 90 dias. Na sequência, selecionam-se alguns padrões entrada/saída do conjunto identificado na primeira etapa: os padrões de saída selecionados correspondem aos valores das demandas médias nos dias j que ocorrem no mesmo dia da semana do dia d da previsão, enquanto os respectivos padrões de entrada incluem a temperatura no dia j e as demandas médias e temperaturas nos dias $j-1$, $j-2$ e $j-7$.




Figura 7. Intervalos de onde são extraídos os padrões entrada/saída para ajuste dos modelos baseados em SVM e RNA.

De forma distinta das abordagens com SVM e RNA, o modelo de regressão dinâmica para previsão da demanda média diária, especificado nas equações (35) e (36), é ajustado com base em todo o histórico disponível.

$$D(d) = \beta_0 + \beta_1 \bar{T}_d + \beta_2 \bar{T}_{d-1} + \beta_3 \bar{T}_{d-2} + \beta_4 \bar{T}_{d-7} + \beta_5 \text{Semana}_d + \beta_6 \text{Mês}_d + \beta_7 \text{Feriado}_d + \eta_d \quad (35)$$

$$\eta_d \sim \text{ARIMA} \quad (36)$$

em que:

- $D(d)$ é a demanda média diária do dia d
- \bar{T}_d é a temperatura média ou máxima diária do dia d
- Semana_d é uma *dummy* do dia da semana no dia d , domingo como categoria de referência
- Mês_d é uma *dummy* do mês no dia d , dezembro como categoria de referência
- Feriado_d é uma *dummy* de feriado no dia d , dia normal como categoria de referência
- η_d é um termo aleatório com resolução temporal diária modelado por um processo estocástico ARIMA

3.2.2 Modelo de previsão do perfil de carga para um dia normal

A previsão do perfil horário de carga para um dia d normal, em p.u. da demanda média diária, é realizada por 24 SVM, um para cada hora $h \forall h=1,24$. O processo de formação do conjunto de padrões entrada/saída considerado no treinamento das 24 máquinas de vetor de suporte (SVM) também tem duas etapas. Inicialmente, o conjunto é formado pelos padrões nas vizinhanças dos dias do histórico na mesma data dia/mês do dia d da previsão, conforme ilustrado na Figura 7. Na sequência, selecionam-se os padrões de entrada/saída no conjunto identificado na primeira etapa, conforme descrito a seguir:

Padrão de saída: demanda horária, em p.u. da demanda média diária, na hora h dos dias j que ocorrem no mesmo dia da semana do dia d da previsão

Padrões de entrada:

- temperatura horária na hora h no dia j e nos dias $j-7$ e $j-14$
- demanda horária (em p.u. da demanda média diária) da hora anterior ($h-1$) e na mesma hora h nos dias $j-7$ e $j-14$.
- previsão da demanda média diária para o dia j
- *dummy* de horário de verão se o dia j pertence ao horário de verão

3.3 Modelo de previsão para dias de feriado/dias especiais

No caso do dia d da previsão ser um dia de feriado/dia especial (Tabela 3), a previsão de demanda média diária também pode ser realizada por modelos SVM, RNA e regressão dinâmica. Contudo, o método de previsão do perfil de carga depende de como foi obtida a previsão da demanda média diária. A previsão do perfil de carga pode ser obtida por um modelo de regressão linear, no caso da demanda média ter sido prevista por regressão dinâmica, ou a previsão do perfil pode ser gerada por 24 SVM se a previsão da demanda média diária foi calculada por SVM ou RNA.

Tabela 3 – Codificação dos feriados e dias especiais.

Tipo do dia	Código
Feriado Nacional perfil de sábado	1
Feriado Nacional perfil de domingo	2
Segunda-feira da semana do Carnaval	3
Terça-feira da semana do Carnaval	4
Quarta-feira de cinzas	5
Natal e 1º de Janeiro	6
Dia após Natal ou após 1º de Janeiro	7
Véspera de Natal ou véspera 1º de Janeiro	8
Véspera de feriado	9
Dia após feriado	10
Dia especial e recesso	11
Blecaute, Jogos da Copa, etc.	12

3.3.1 Modelo de previsão da demanda média diária em dias de feriado/dias especiais

Se o dia d da previsão é um dia de feriado/dia especial, o PrecvargaDESSEM 2.0 treina modelos SVM ou RNA ou ajusta um modelo de regressão dinâmica para a previsão da demanda média diária em MW.

Para o treinamento de modelos SVM ou RNA o programa oferece três alternativas: RNA (com dois neurônios em uma camada escondida), SVM com *kernel* linear e SVM com *kernel* radial. Neste caso, as variáveis de entrada incluem:

- *dummy* de feriado do dia da previsão (dia normal como referência)
- *dummy* do horário verão do dia da previsão (período de horário normal como referência)
- *dummy* do mês do dia da previsão (dezembro como mês de referência)
- demandas médias dos dias $d-1$, $d-2$ e $d-7$
- temperaturas médias nos dias $d-1$, $d-2$ e $d-7$, sendo que para a temperatura o programa oferece quatro especificações possíveis: sem temperatura, média da temperatura diária, temperatura máxima diária e valores mínimo e máximo da temperatura diária.

O treinamento da RNA e SVM é realizado a partir de todos os dados do histórico no mesmo dia da semana do dia d da previsão.

Alternativamente, a previsão da demanda média diária nos dias de feriado/dias especiais pode ser realizada pela equação resultante do ajuste do seguinte modelo de regressão dinâmica:

$$D(d) = \beta_0 + \beta_1 \bar{T}_d + \beta_2 \bar{T}_{d-1} + \beta_3 \bar{T}_{d-2} + \beta_4 \bar{T}_{d-7} + \beta_5 \text{Semana}_d + \beta_6 \text{Mês}_d + \beta_7 \text{Feriado}_d + \eta_d \quad (37)$$

$$\eta_d \sim \text{ARIMA} \quad (38)$$

em que:

- $D(d)$ é a demanda média diária do dia d
- \bar{T}_d é a temperatura média ou máxima diária do dia d
- Semana_d é uma *dummy* do dia da semana no dia d , domingo como categoria de referência
- Mês_d é uma *dummy* do mês no dia d , dezembro como categoria de referência
- Feriado_d é uma *dummy* de feriado no dia d , dia normal como categoria de referência
- η_d é um termo aleatório com resolução temporal diária modelado por um processo estocástico ARIMA

De forma distinta das abordagens com SVM e RNA, o modelo de regressão dinâmica em (37) e (38) é ajustado com base em todo o histórico disponível.

3.3.2 Modelo SVM para previsão do perfil de carga para um dia de feriado/dia especial

No caso da previsão da demanda média diária ter sido realizada por SVM ou RNA, a previsão do perfil de carga para um dia d que seja feriado/dia especial (em p.u. da demanda média diária) é realizada por 24 SVM, um para cada hora $h \forall h=1,24$.

A previsão do perfil de carga nos feriados dos tipos 1,2,3,4,5,6 e 7 corresponde à uma combinação dos perfis de carga do sábado e do domingo imediatamente anteriores ao dia da previsão. Já nos demais dias de feriados/dias especiais a previsão do perfil da curva de carga é uma combinação dos perfis verificados no sábado e na segunda-feira imediatamente anteriores ao dia da previsão. Nos dois casos a combinação dos perfis é realizada por meio de máquinas de vetor de suporte, uma para cada hora do dia.

Na previsão dos perfis de carga para os feriados dos tipos 1,2,3,4,5,6 e 7 o processo de formação do conjunto de padrões entrada/saída considerado no treinamento das 24 SVM tem duas etapas. Inicialmente, o conjunto é formado pelos padrões nas vizinhanças dos dias do histórico com feriados/dias especiais dos tipos 1,2,3,4,5,6 e 7, conforme ilustrado na Figura 8. Na sequência, selecionam-se os padrões de entrada/saída no conjunto identificado na primeira etapa, conforme descrito a seguir:

Padrão de saída: demanda horária, em p.u. da demanda média diária, na hora h dos dias j que são feriados/dias especiais do tipo 1,2,3,4,5,6 e 7.

Padrões de entrada:

- temperatura horária na hora h no dia j e nos dias $j-7$ e $j-14$
- demanda horária (em p.u. da demanda média diária) da hora anterior ($h-1$)
- Demanda horária na mesma hora h do sábado imediatamente anterior ao dia j
- Demanda horária na mesma hora h do domingo imediatamente anterior ao dia j
- Demanda média diária para o dia j
- *dummy* de horário de verão se o dia j pertence ao horário de verão
- *dummy* de tipo de feriado/dia especial do dia j , desde que sejam dos tipos 1,2,3,4,5,6 e 7




Figura 8. Intervalos de onde são extraídos os dados para o ajuste dos modelos de previsão do perfil de feriado.

Na previsão dos perfis de carga para os demais tipos de feriados/dias especiais o conjunto de padrões entrada/saída considerado no treinamento das 24 máquinas de vetor de suporte (SVM) é formado por todos os dias do histórico que sejam marcados como sendo dos demais tipos de feriados/dias especiais. Os padrões de entrada/saída são especificados conforme a seguir:

Padrão de saída: demanda horária, em p.u. da demanda média diária, na hora h dos dias j que são feriados/dias especiais, mas diferentes dos tipos 1,2,3,4,5,6 e 7.

Padrões de entrada:

- temperatura horária na hora h no dia j e nos dias $j-7$ e $j-14$
- demanda horária (em p.u. da demanda média diária) da hora anterior ($h-1$).
- Demanda horária na mesma hora h do sábado imediatamente anterior
- Demanda horária na mesma hora h da segunda-feira imediatamente anterior
- Demanda média diária para o dia j
- *dummy* de horário de verão se o dia j pertence ao horário de verão
- *dummy* de tipo de feriado do dia j , desde que sejam diferentes de 1,2,3,4,5,6 e 7

3.3.3 Modelo de regressão linear para previsão do perfil de carga em feriados/dia especial

Conforme mencionado na seção 3.3.2, a previsão do perfil de carga nos feriados dos tipos 1,2,3,4,5,6 e 7 corresponde à uma combinação dos perfis de carga do sábado e do domingo imediatamente anteriores ao dia da previsão. Já nos demais dias de feriados/dias especiais a previsão do perfil da curva de carga é uma combinação dos perfis verificados no sábado e na segunda-feira imediatamente anteriores ao dia da previsão. Nos dois casos a combinação dos perfis é realizada por meio de um modelo de regressão linear múltipla.

Apesar das semelhanças na modelagem, os modelos de regressão linear múltipla em cada caso diferem na especificação da equação de regressão e na forma como são construídas as amostras de dados usadas no ajuste dos modelos.

No caso da previsão de carga para um feriado do tipo j pertencente ao conjunto $\{1,2,3,4,5,6,7\}$, a amostra é formada pelos perfis de carga dos feriados tipo j no histórico, acompanhados dos respectivos perfis de sábados e domingos imediatamente anteriores ao feriado, mas todos pertencentes à vizinhança ao redor do feriado, conforme ilustrado na Figura 8.

Nos demais feriados a quantidade de exemplos é bem restrita e a amostra é formada pelos perfis de feriados do mesmo tipo do feriado do dia d da previsão, acompanhados dos respectivos perfis de sábado e segunda-feira imediatamente anteriores ao feriado. Neste caso, o conjunto de dados usados no ajuste do modelo de regressão linear múltipla considera todos os dias com feriados do mesmo tipo do feriado no dia d da previsão disponíveis no histórico.

Para os feriados marcados como sendo dos tipos 1,2,3,4,5,6 e 7 o modelo de regressão linear múltipla tem a seguinte especificação:

$$Z_{feriado}(d, h) = \beta_0 + \beta_1 T(d, h) + \beta_2 Hora_d + \beta_3 Z_{sábado,d}(h) + \beta_4 Z_{domingo,d}(h) + \varepsilon_{d,h} \quad (39)$$

em que:

- $T(d, h)$ é a temperatura média na hora h do dia d
- $Hora_d$ é uma *dummy* horária
- $Z_{feriado}(d, h) = [D(d, h) - \bar{D}(d)]/S_d$ é o valor padronizado da carga na hora h e no feriado do dia d , $D(d, h)$, e $\bar{D}(d)$ e S_d são, respectivamente, a média e o desvio padrão das demandas horárias do dia d .
- $Z_{sábado,d}(h) = [D(sábado_d, h) - \overline{sábado_d}]/S_{sábado,d}$ é o valor padronizado da carga na hora h e no sábado imediatamente anterior ao feriado do dia d , $D(sábado_d, h)$, e $\overline{sábado_d}$ e $S_{sábado,d}$ são, respectivamente, a média e o desvio padrão das demandas horárias do sábado imediatamente anterior ao dia d .
- $Z_{domingo,d}(h) = [D(domingo_d, h) - \overline{domingo_d}]/S_{domingo,d}$ é o valor padronizado da carga na hora h e no domingo imediatamente anterior ao feriado do dia d , $D(domingo_d, h)$, e $\overline{domingo_d}$ e $S_{domingo,d}$ são, respectivamente, a média e o desvio padrão das demandas horárias do domingo imediatamente anterior ao dia d .

Uma vez ajustado o modelo em (39), a previsão de carga para a hora h no feriado do dia d é dada pela seguinte equação:

$$\hat{D}(d, h) = [\hat{\beta}_0 + \hat{\beta}_1 T(d, h) + \hat{\beta}_2 Hora_d + \hat{\beta}_3 Z_{sábado,d}(h) + \hat{\beta}_4 Z_{domingo,d}(h)] \bar{S}_d + \bar{D}(d) \quad (40)$$

em que $\hat{\beta}$ denota as estimativas dos coeficientes de regressão, $T(d, h)$ é a previsão de temperatura para a hora h do dia d , $Z_{sábado,d}(h)$ é a carga padronizada da hora h no sábado imediatamente anterior ao dia d , $Z_{domingo,d}(h)$ é a carga padronizada da hora h no domingo imediatamente anterior ao dia d , \bar{S}_d é a média dos desvios padrão e $\bar{D}(d)$ é a previsão da demanda média diária, ambos para o dia d .

Para os demais feriados o modelo de regressão linear múltipla é ligeiramente diferente e tem a seguinte especificação:

$$Z_{feriado}(d, h) = \beta_0 + \beta_1 T(d, h) + \beta_2 Hora_d + \beta_3 Z_{sábado,d}(h) + \beta_4 Z_{segunda-feira,d}(h) + \varepsilon_{d,h} \quad (41)$$

em que:

- $T(d, h)$ é a temperatura média na hora h do dia d
- $Hora_d$ é uma *dummy* horária
- $Z_{feriado}(d, h) = [D(d, h) - \bar{D}(d)]/S_d$ é o valor padronizado da carga na hora h e no feriado do dia d , $D(d, h)$, e $\bar{D}(d)$ e S_d são, respectivamente, a média e o desvio padrão das demandas horárias do dia d .
- $Z_{sábado,d}(h) = [D(sábado_d, h) - \overline{sábado_d}]/S_{sábado,d}$ é o valor padronizado da carga na hora h e no sábado imediatamente anterior ao feriado do dia d , $D(sábado_d, h)$, e $\overline{sábado_d}$ e $S_{sábado,d}$ são, respectivamente, a média e o desvio padrão das demandas horárias do sábado imediatamente anterior ao dia d .
- $Z_{segunda-feira,d}(h) = [D(segunda-feira_d, h) - \overline{segunda-feira_d}]/S_{segunda-feira,d}$ é o valor padronizado da carga na hora h e na segunda-feira imediatamente anterior ao feriado do dia d ,

$\bar{D}(\text{segunda} - \text{feira}_d, h)$, $\overline{\text{segunda} - \text{feira}_d}$ e $S_{\text{segunda} - \text{feira}_d}$ são, respectivamente, a média e o desvio padrão das demandas horárias da segunda-feira imediatamente anterior ao dia d .

Uma vez ajustado o modelo em (41), a previsão de carga para a hora h no feriado do dia d é dada pela seguinte equação:

$$\hat{D}(d, h) = [\hat{\beta}_0 + \hat{\beta}_1 T(d, h) + \hat{\beta}_2 \text{Hora}_d + \hat{\beta}_3 Z_{\text{sábado}, d}(h) + \hat{\beta}_4 Z_{\text{segunda} - \text{feira}, d}(h)] \bar{S}_d + \bar{D}(d) \quad (42)$$

em que $\hat{\beta}$ denota as estimativas dos coeficientes de regressão, $T(d, h)$ é a previsão de temperatura para a hora h do dia d , $Z_{\text{sábado}, d}(h)$ é a carga padronizada da hora h no sábado imediatamente anterior ao dia d , $Z_{\text{segunda} - \text{feira}, d}(h)$ é a carga padronizada da hora h na segunda-feira imediatamente anterior ao dia d , \bar{S}_d é a média dos desvios padrão e $\bar{D}(d)$ é a previsão da demanda média diária, ambos para o dia d .

3.4 Previsão combinada

Conforme ilustrado na Tabela 4, o PrecvargaDESSEM 2.0 oferece 14 possibilidades para a previsão da demanda média diária dos dias normais. O programa permite que o usuário execute cada uma das 14 modelagens disponíveis e obtenha a previsão obtida por cada modelo (previsão individual) ou faça uma execução em lote dos 14 modelos e ao final calcule a média ponderada das previsões (previsão combinada), com ponderações calculadas previamente pelo ONS. Bates e Granger (1969) mostram que previsão combinada é melhor que as previsões individuais. Cada modelo de previsão da demanda média diária na Tabela 4 vem acompanhado de um modelo de previsão de perfil de carga na Tabela 5.

Tabela 4 – Modelos de previsão da demanda média diária para os dias normais.

	Sem temperatura	Temperatura média	Temperatura máxima	Temperatura mínima e máxima
SVM com kernel linear	✓ Linear.Univariado	✓ Linear.TmpMedia	✓ Linear.TmpMaxima	✓ Linear.TmpMaxMin
SVM com kernel radial	✓ Radial.Univariado	✓ Radial.TmpMedia	✓ Radial.TmpMaxima	✓ Radial.TmpMaxMin
RNA	✓ RedeNeural.Univariado	✓ RedeNeural.TmpMaxMin	✓ RedeNeural.TmpMaxima	✓ RedeNeural.TmpMaxMin
RD		✓ RegDin.Radial.TmpMed	✓ RegDin.Radial.TmpMax	

Nota: SVM = Máquina de Vetor de Suporte, RNA = Redes Neurais Artificiais e RD = Regressão Dinâmica

Tabela 5 – Modelos de previsão do perfil de carga para os dias normais

	Sem temperatura	Temperatura média	Temperatura máxima	Temperatura mínima e máxima
SVM com kernel linear	✓ 24 SVM	✓ 24 SVM	✓ 24 SVM	✓ 24 SVM

SVM com kernel radial	✓ 24 SVM	✓ 24 SVM	✓ 24 SVM	✓ 24 SVM
RNA	✓ 24 SVM	✓ 24 SVM	✓ 24 SVM	✓ 24 SVM
RD		✓ 24 SVM	✓ 24 SVM	

Nota: SVM = Máquina de Vetor de Suporte, RNA = Redes Neurais Artificiais e RD = Regressão Dinâmica

4. Programa PrecargaDESSEM 2.0

4.1 Instalação

O PrecargaDESSEM 2.0 é um pacote desenvolvido para o ambiente “R” (R CORE TEAM, 2017). Assim, antes da instalação do PrecargaDESSEM recomenda-se a instalação de uma versão do R para Windows mais nova que a versão 4.0.5. A interface com o programa é realizada por meio de arquivos no formato “csv” (arquivo texto com colunas separadas por “,”) ou por objetos “data.frame”.

Para instalar o PrecargaDESSEM 2.0 copie o arquivo precargadessem.zip para algum diretório. Na sequência, acesse o R e use a opção do menu "Pacotes/Instalar pacote(s) a partir de arquivos zip locais..." (Figura 9) para instalar o pacote

prevcargadessem disponibilizado no arquivo prevcargadessem.tar.gz. Durante a instalação serão instalados outros pacotes R usados pelo programa.

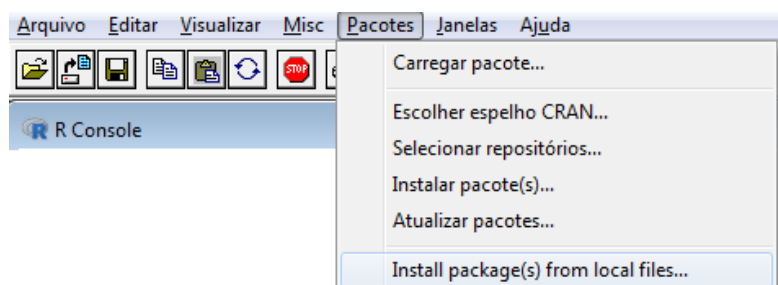


Figura 9. Menu Pacotes e opção *Install package(s) from local files*.

4.2 Arquivos de dados

Os arquivos com os dados de entrada para o PrecvargaDESSEM 2.0 são disponibilizados no Portal Sintegre do ONS (<https://sintegre.ons.org.br>). Os dados estão disponíveis em arquivos zip, datados e disponíveis sob o título “decks para previsão de carga para o DESSEM” para cada subsistema. Em cada arquivo zip há 6 arquivos no formato csv, conforme ilustrado na Tabela 6, em que XX denota o acrônimo identificador da carga e AAAA-MM-DD a data do arquivo no formato ano/mês/dia.

Tabela 6. Arquivos de entrada do PrecvargaDESSEM 2.0.

Nome do arquivo	Conteúdo
XX_AAAA-MM-DD_CARGAHIST.CSV	Dados históricos da carga global em base horária
XX_AAAA-MM-DD_COMBINA.CSV	Pesos das previsões no cálculo da previsão combinada
XX_AAAA-MM-DD_EXOGENAHIST.CSV	Dados históricos de temperatura equivalente em base horária
XX_AAAA-MM-DD_EXOGENAPREV.CSV	Previsões de temperatura equivalente em base horária
XX_AAAA-MM-DD_FERIADOS.CSV	Datas de feriados nacionais e estaduais
XX_AAAA-MM-DD_PATAMARES.CSV	Dados dos intervalos dos patamares de carga

4.2.1 Histórico da carga global em base horária

Os dados de carga são disponibilizados em bases horárias e organizados em arquivos ".csv" com colunas separadas por ponto e vírgula. Cada média horária da carga deve ser acompanhado da respectiva data de ocorrência (ano/mês/dia/hora/minuto), conforme ilustrado na Figura 10.

	A	B
1	DataHora	Carga
2	01/01/2016 01:00	32.420,16
3	01/01/2016 02:00	32.259,22
4	01/01/2016 03:00	31.836,60
5	01/01/2016 04:00	31.241,38
6	01/01/2016 05:00	30.706,56
7	01/01/2016 06:00	30.219,25
8	01/01/2016 07:00	28.526,89
9	01/01/2016 08:00	27.597,67
10	01/01/2016 09:00	28.201,34
11	01/01/2016 10:00	29.314,13
12	01/01/2016 11:00	30.369,25
13	01/01/2016 12:00	31.100,42
14	01/01/2016 13:00	30.984,63
15	01/01/2016 14:00	30.235,98
16	01/01/2016 15:00	29.735,44
17	01/01/2016 16:00	29.660,75
18	01/01/2016 17:00	29.826,78
19	01/01/2016 18:00	30.289,94
20	01/01/2016 19:00	30.987,40
21	01/01/2016 20:00	32.948,59
22	01/01/2016 21:00	36.433,68

Figura 10. Exemplo de arquivo XX_AAAA-MM-DD_CARGAHIST.CSV.

4.2.2 Pesos das previsões no cálculo da previsão combinada

O arquivo XX_AAAA-MM-DD_COMBINA.CSV contém a ponderação dos modelos de previsão para cada intervalo semi-horário ao longo de um horizonte de previsão de 8 dias, i.e., 384 conjuntos de ponderação. Este arquivo deve ser informado no caso da execução de uma previsão combinada, cujo resultado é a soma ponderada das previsões obtidas por cada um dos 14 modelos de previsão disponibilizados pelo PrcargaDESSEM 2.0 listados abaixo:

- SVM com kernel linear e temperatura máxima
- SVM com kernel linear e temperaturas máxima e mínima
- SVM com kernel linear e temperatura média
- SVM com kernel linear e sem temperatura
- SVM com kernel radial e temperatura máxima
- SVM com kernel radial e temperaturas máxima e mínima
- SVM com kernel radial e temperatura média
- SVM com kernel radial e sem temperatura
- Rede neural artificial e temperatura máxima
- Rede neural artificial e temperaturas máxima e mínima
- Rede neural artificial e temperatura média
- Rede neural artificial e sem temperatura
- Regressão dinâmica e temperatura máxima
- Regressão dinâmica e temperatura média

Os pesos atribuídos às previsões obtidas pelos diferentes modelos disponibilizados no PrcargaDESSEM 2.0 são organizados em arquivos ".csv" com colunas separadas por vírgula, conforme ilustrado na Figura 11, na qual pode-se observar o primeiro dos 384 conjuntos de pesos (passo 1), os demais conjuntos são listados no mesmo arquivo.

	A	B	C
1	Modelo	Coefficient	Passo
2	(Intercept)	0	1
3	Linear.TmpMaxMin	0,083333	1
4	Linear.TmpMaxima	0,083333	1
5	Linear.TmpMedia	0,083333	1
6	Linear.Univariado	0,083333	1
7	Radial.TmpMaxMin	0,083333	1
8	Radial.TmpMaxima	0,083333	1
9	Radial.TmpMedia	0,083333	1
10	Radial.Univariado	0,083333	1
11	RedeNeural.TmpMaxMin	0,083333	1
12	RedeNeural.TmpMaxima	0,083333	1
13	RedeNeural.TmpMedia	0,083333	1
14	RedeNeural.Univariado	0,083333	1

Figura 11. Exemplo de arquivo XX_AAAA-MM-DD_COMBINA.CSV.

4.2.3 Lista de feriados e dias especiais

A tabela com informações de feriados e dias especiais deve conter a data de cada feriado (no formato ano/mês/dia) ao longo do período do histórico de carga e o tipo do feriado/dia especial, cuja codificação deve seguir a nomenclatura indicada na

Tipo do dia	Código
Feriado Nacional perfil de sábado	1
Feriado Nacional perfil de domingo	2
Segunda-feira da semana do Carnaval	3
Terça-feira da semana do Carnaval	4
Quarta-feira de cinzas	5
Natal e 1º de Janeiro	6
Dia após Natal ou após 1º de Janeiro	7
Véspera de Natal ou véspera 1º de Janeiro	8
Véspera de feriado	9
Dia após feriado	10
Dia especial e recesso	11
Blecaute, Jogos da Copa, etc.	12

a) Codificação de feriados e dias especiais

Figura 12a. Na

Tipo do dia	Código
Feriado Nacional perfil de sábado	1
Feriado Nacional perfil de domingo	2
Segunda-feira da semana do Carnaval	3
Terça-feira da semana do Carnaval	4
Quarta-feira de cinzas	5
Natal e 1º de Janeiro	6
Dia após Natal ou após 1º de Janeiro	7
Véspera de Natal ou véspera 1º de Janeiro	8
Véspera de feriado	9
Dia após feriado	10
Dia especial e recesso	11
Blecaute, Jogos da Copa, etc.	12

a) Codificação de feriados e dias especiais

Figura 12b tem-se um exemplo do arquivo XX_AAAA-MM-DD_FERIADOS.CSV com dados de feriados e dias especiais.

Tipo do dia	Código
Feriado Nacional perfil de sábado	1
Feriado Nacional perfil de domingo	2
Segunda-feira da semana do Carnaval	3
Terça-feira da semana do Carnaval	4
Quarta-feira de cinzas	5
Natal e 1º de Janeiro	6
Dia após Natal ou após 1º de Janeiro	7
Véspera de Natal ou véspera 1º de Janeiro	8
Véspera de feriado	9
Dia após feriado	10
Dia especial e recesso	11
Blecaute, Jogos da Copa, etc.	12

a) Codificação de feriados e dias especiais

Figura 12. Arquivo XX_AAAA-MM-DD_FERIADOS.CSV com datas de feriados e dias especiais.

	A	B
1	Data	Tipo
2	01/01/2016	6
3	02/01/2016	7
4	20/01/2016	11
5	05/02/2016	9
6	08/02/2016	3
7	09/02/2016	4
8	10/02/2016	5
9	24/03/2016	9
10	25/03/2016	2
11	27/03/2016	2
12	21/04/2016	1
13	22/04/2016	11
14	26/05/2016	1
15	27/05/2016	11
16	09/07/2016	11
17	07/09/2016	1
18	08/09/2016	10

b) Arquivo XX_AAAA-MM-DD_FERIADOS.CSV

	A	B
1	Data	Tipo
2	01/01/2016	6
3	02/01/2016	7
4	20/01/2016	11
5	05/02/2016	9
6	08/02/2016	3
7	09/02/2016	4
8	10/02/2016	5
9	24/03/2016	9
10	25/03/2016	2
11	27/03/2016	2
12	21/04/2016	1
13	22/04/2016	11
14	26/05/2016	1
15	27/05/2016	11
16	09/07/2016	11
17	07/09/2016	1
18	08/09/2016	10

b) Arquivo XX_AAAA-MM-DD_FERIADOS.CSV

	A	B
1	Data	Tipo
2	01/01/2016	6
3	02/01/2016	7
4	20/01/2016	11
5	05/02/2016	9
6	08/02/2016	3
7	09/02/2016	4
8	10/02/2016	5
9	24/03/2016	9
10	25/03/2016	2
11	27/03/2016	2
12	21/04/2016	1
13	22/04/2016	11
14	26/05/2016	1
15	27/05/2016	11
16	09/07/2016	11
17	07/09/2016	1
18	08/09/2016	10

b) Arquivo XX_AAAA-MM-DD_FERIADOS.CSV

4.2.4 Histórico das temperaturas horárias

O arquivo com dados históricos de temperatura deve conter os valores médios da temperatura equivalente (°C) em base horária. Adicionalmente, cada valor médio deve ser acompanhado da respectiva data de ocorrência, especificada em termos de ano/mês/dia/hora/minuto, conforme ilustrado na Figura 13.

	A	B
1	DataHora	Temperatura
2	01/01/2016 00:00	25,39
3	01/01/2016 01:00	25,39
4	01/01/2016 02:00	25,06
5	01/01/2016 03:00	24,73
6	01/01/2016 04:00	24,64
7	01/01/2016 05:00	24,14
8	01/01/2016 06:00	23,49
9	01/01/2016 07:00	24,18
10	01/01/2016 08:00	25,17
11	01/01/2016 09:00	27,88
12	01/01/2016 10:00	29,46
13	01/01/2016 11:00	30,92
14	01/01/2016 12:00	32,49
15	01/01/2016 13:00	32,44
16	01/01/2016 14:00	32,15
17	01/01/2016 15:00	31,91
18	01/01/2016 16:00	30,50

Figura 13. Exemplo do arquivo XX_AAAA-MM-DD_EXOGENAHIST.CSV.

4.2.5 Previsão das temperaturas horárias

O arquivo com previsões de temperatura deve conter os valores médios da temperatura equivalente (°C) em base horária ao longo do período de previsão. Cada linha do arquivo deve conter uma previsão da média horária de temperatura equivalente e sua respectiva data especificada como ano/mês/dia/hora/minuto, conforme ilustrado na Figura 14.

	A	B
1	DataHora	Temperatura
2	16/06/2021 00:00	17,71
3	16/06/2021 01:00	17,41
4	16/06/2021 02:00	17,02
5	16/06/2021 03:00	16,59
6	16/06/2021 04:00	16,24
7	16/06/2021 05:00	16,10
8	16/06/2021 06:00	15,81
9	16/06/2021 07:00	15,85
10	16/06/2021 08:00	17,37
11	16/06/2021 09:00	19,62
12	16/06/2021 10:00	21,62
13	16/06/2021 11:00	23,24
14	16/06/2021 12:00	24,25
15	16/06/2021 13:00	24,84
16	16/06/2021 14:00	25,24
17	16/06/2021 15:00	25,30
18	16/06/2021 16:00	25,08

Figura 14. Exemplo do arquivo XX_AAAA-MM-DD_EXOGENAPREV.CSV com previsões de temperatura equivalente.

4.2.6 Intervalos de duração dos patamares de carga

Um extrato do arquivo com os intervalos de duração dos patamares de carga é ilustrado a seguir:

	A	B	C	D	E	F	G
1	Hora	dia.util.inverno	fds.inverno	dia.util.intermediario	fds.intermediario	dia.util.verao	fds.verao
2	00:00	3	3	3	3	3	3
3	01:00	3	3	3	3	3	3
4	02:00	3	3	3	3	3	3
5	03:00	3	3	3	3	3	3
6	04:00	3	3	3	3	3	3
7	05:00	3	3	3	3	3	3
8	06:00	3	3	3	3	3	3
9	07:00	2	3	3	3	3	3
10	08:00	2	3	2	3	2	3
11	09:00	2	3	2	3	2	3
12	10:00	1	3	1	3	1	3
13	11:00	1	3	1	3	1	3
14	12:00	1	3	1	3	1	3
15	13:00	1	3	1	3	1	3
16	14:00	1	3	1	3	1	3
17	15:00	1	3	1	3	1	3
18	16:00	1	3	1	3	1	3
19	17:00	1	3	1	3	1	3
20	18:00	1	2	1	2	2	3
21	19:00	1	2	1	2	2	3
22	20:00	1	2	2	2	2	2

Figura 15. Arquivo XX_AAAA-MM-DD_PATAMARES.CSV.

5. Execução em ambiente R

A previsão de carga é obtida pela função *previsordessem*, cujos parâmetros de entrada são descritos a seguir:

previsordessem(deck,data,horizonte,maxTreads,modelos,saída,dirSaida)

deck = Nome da pasta onde está o conjunto de dados fornecido no Sintegre NOS, por exemplo, “c:/tests/deckn/”

data = Data do deck de dados que será analisado, por exemplo, “2021-12-30”

horizonte = “10DIAS” para 10 dias à frente ou “SEMOP” para semana operativa, i.e., até 8 dias à frente

maxTreads = Limita o número de *cores* de processamento da máquina, caso nulo o programa usa o máximo de *cores* disponíveis

modelos = Nome do modelo de previsão a ser executado, se nulo todos os modelos serão executados. Use a função *obterModelos()* para listar os nomes dos 14 modelos disponíveis: “Radial.TmpMaxima”, “Radial.TmpMedia”, “Radial.TmpMaxMin”, “Radial.Univariado”, “RedeNeural.TmpMaxima”, “RedeNeural.TmpMedia”, “RedeNeural.TmpMaxMin”, “RedeNeural.Univariado”, “Linear.TmpMaxima”, “Linear.TmpMedia”, “Linear.TmpMaxMin”, “Linear.Univariado”, “RegDin.Radial.TmpMax”, “RegDin.Radial.TmpMed”. A combinação das previsões é realizada mediante as ponderações informadas no arquivo XX_AAAA-MM-DD_COMBINA.csv disponibilizado no Sintegre ONS. Na ausência deste arquivo o PrecvargaDESSEM 2.0 fornece as previsões obtidas pelos modelos, porém, sem combiná-las.

saída = Opções para o formato de saída das previsões:

- Por *default* as previsões disponibilizadas em um objeto R data.Table (Figura 16)
- “CSV” = previsões disponibilizadas em um arquivo texto em formato csv (Figura 17)
- “PLOT” = gráfico das previsões (Figura 18)
- “DESSEM” = previsões disponibilizadas em arquivo texto para o DESSEM (Figura 19)

dirSaida = Diretório de saída, por *default* é o mesmo local onde estão os arquivos de entrada

Vale destacar que o programa gera um arquivo de *log* DataHora_log_prevcargadessem.txt (Figura 20) com mensagens do *status* em cada etapa do processamento da previsão.

	DataHora	Carga	Modelo
1	2021-06-16 00:30:00	35039.46	Combinado
2	2021-06-16 01:00:00	34061.98	Combinado
3	2021-06-16 01:30:00	33028.08	Combinado
4	2021-06-16 02:00:00	32269.31	Combinado
5	2021-06-16 02:30:00	31772.80	Combinado
6	2021-06-16 03:00:00	31390.96	Combinado
7	2021-06-16 03:30:00	31144.12	Combinado
8	2021-06-16 04:00:00	31048.50	Combinado
9	2021-06-16 04:30:00	31094.63	Combinado
10	2021-06-16 05:00:00	31421.14	Combinado
11	2021-06-16 05:30:00	31994.01	Combinado
12	2021-06-16 06:00:00	32950.06	Combinado
13	2021-06-16 06:30:00	34348.75	Combinado
14	2021-06-16 07:00:00	35385.65	Combinado
15	2021-06-16 07:30:00	36050.62	Combinado
16	2021-06-16 08:00:00	36940.17	Combinado
17	2021-06-16 08:30:00	38041.77	Combinado

Figura 16 – Extrato do objeto Data.Table com as previsões semi-horárias geradas pelo PrecvargaDESSEM 2.0, na figura são exibidas apenas as previsões resultantes da combinação

	A	B	C	D	E	F
1	DataHora	Carga	Modelo			
2	16/06/2021 00:30	35039,46	Combinado			
3	16/06/2021 01:00	34061,98	Combinado			
4	16/06/2021 01:30	33028,08	Combinado			
5	16/06/2021 02:00	32269,31	Combinado			
6	16/06/2021 02:30	31772,8	Combinado			
7	16/06/2021 03:00	31390,96	Combinado			
8	16/06/2021 03:30	31144,12	Combinado			
9	16/06/2021 04:00	31048,5	Combinado			
10	16/06/2021 04:30	31094,63	Combinado			
11	16/06/2021 05:00	31421,14	Combinado			
12	16/06/2021 05:30	31994,01	Combinado			
13	16/06/2021 06:00	32950,06	Combinado			
14	16/06/2021 06:30	34348,75	Combinado			
15	16/06/2021 07:00	35385,65	Combinado			
16	16/06/2021 07:30	36050,62	Combinado			
17	16/06/2021 08:00	36940,17	Combinado			
18	16/06/2021 08:30	38041,77	Combinado			
19	16/06/2021 09:00	38760,63	Combinado			
20	16/06/2021 09:30	39105,94	Combinado			
21	16/06/2021 10:00	39503,69	Combinado			
22	16/06/2021 10:30	39942,1	Combinado			
23	16/06/2021 11:00	40086,73	Combinado			
24	16/06/2021 11:30	39967,06	Combinado			
25	16/06/2021 12:00	39825,71	Combinado			

Figura 17 – Extrato do arquivo csv com as previsões semi-horárias geradas pelo PrecvargaDESSEM 2.0, na figura são exibidas apenas as previsões resultantes da combinação




Figura 18 – Gráfico com as previsões dos 14 modelos

5	&	ss	di	hi	m	df	hf	m	Demanda
6	&X	XX	XX	XX	X	XX	XX	X	XXXXXXXXXX
7	DP	1	12	0	0	F			36751
8	DP	1	12	0	1	F			35675
9	DP	1	12	1	0	F			34667
10	DP	1	12	1	1	F			33788
11	DP	1	12	2	0	F			33372
12	DP	1	12	2	1	F			32885
13	DP	1	12	3	0	F			32662
14	DP	1	12	3	1	F			32527
15	DP	1	12	4	0	F			32555
16	DP	1	12	4	1	F			32883
17	DP	1	12	5	0	F			33457
18	DP	1	12	5	1	F			33623
19	DP	1	12	6	0	F			34785
20	DP	1	12	6	1	F			35640
21	DP	1	12	7	0	F			36996
22	DP	1	12	7	1	F			38266
23	DP	1	12	8	0	F			39492
24	DP	1	12	8	1	F			40188
25	DP	1	12	9	0	F			40735
26	DP	1	12	9	1	F			41192
27	DP	1	12	10	0	F			41570
28	DP	1	12	10	1	F			41855
29	DP	1	12	11	0	F			41960
30	DP	1	12	11	1	F			41915
31	DP	1	12	12	0	F			41529
32	DP	1	12	12	1	F			41594
33	DP	1	12	13	0	F			42203
34	DP	1	12	13	1	F			42786
35	DP	1	12	14	0	F			43112
36	DP	1	12	14	1	F			43441
37	DP	1	12	15	0	F			43671
38	DP	1	12	15	1	F			43843
39	DP	1	12	16	0	F			43713
40	DP	1	12	16	1	F			43479
41	DP	1	12	17	0	F			42690
42	DP	1	12	17	1	F			42825
43	DP	1	12	18	0	F			43487
44	DP	1	12	18	1	F			45073
45	DP	1	12	19	0	F			45457
46	DP	1	12	19	1	F			44912
47	DP	1	12	20	0	F			44477
48	DP	1	12	20	1	F			44103
49	DP	1	12	21	0	F			43478
50	DP	1	12	21	1	F			42650
51	DP	1	12	22	0	F			41722
52	DP	1	12	22	1	F			40619
53	DP	1	12	23	0	F			39496
54	DP	1	12	23	1	F			38833

Figura 19 – Extrato do arquivo texto com as previsões de carga para o DESSEM


```
20211221134827_logprevcargadessem.txt
1 starting worker pid=17940 on localhost:11387 at 13:48:28.499
2 starting worker pid=23900 on localhost:11387 at 13:48:28.764
3 starting worker pid=33452 on localhost:11387 at 13:48:29.018
4 starting worker pid=5296 on localhost:11387 at 13:48:29.258
5 starting worker pid=23048 on localhost:11387 at 13:48:29.469
6 starting worker pid=24428 on localhost:11387 at 13:48:29.702
7 starting worker pid=6756 on localhost:11387 at 13:48:29.947
8 Radial.TmpMaxima - 2021-12-21 13:48:36 - Processando...
9 Radial.TmpMaxMin - 2021-12-21 13:48:36 - Processando...
10 RedeNeural.TmpMaxima - 2021-12-21 13:48:36 - Processando...
11 RedeNeural.TmpMaxMin - 2021-12-21 13:48:36 - Processando...
12 Linear.TmpMaxima - 2021-12-21 13:48:36 - Processando...
13 Linear.TmpMaxMin - 2021-12-21 13:48:36 - Processando...
14 RegDin.Radial.TmpMax - 2021-12-21 13:48:36 - Processando...
15 Radial.TmpMaxima - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
16 Radial.TmpMaxMin - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
17 RedeNeural.TmpMaxima - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
18 RedeNeural.TmpMaxMin - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
19 Linear.TmpMaxima - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
20 Linear.TmpMaxMin - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
21 RegDin.Radial.TmpMax - 2021-12-21 13:48:36 - Estruturando series de Perfil e Demanda Media...
22 RegDin.Radial.TmpMax - 2021-12-21 13:48:37 - Executando previsoes...
23 RegDin.Radial.TmpMax - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16,2021-06-17,2021-06-18,2021-06-19,2021-06-20,2021-06-21,2021-06-22,2021-06-23
24 RedeNeural.TmpMaxima - 2021-12-21 13:48:37 - Executando previsoes...
25 RedeNeural.TmpMaxima - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16
26 Linear.TmpMaxima - 2021-12-21 13:48:37 - Executando previsoes...
27 Linear.TmpMaxima - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16
28 Radial.TmpMaxima - 2021-12-21 13:48:37 - Executando previsoes...
29 Radial.TmpMaxima - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16
30 Radial.TmpMaxMin - 2021-12-21 13:48:37 - Executando previsoes...
31 Radial.TmpMaxMin - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16
32 RedeNeural.TmpMaxMin - 2021-12-21 13:48:37 - Executando previsoes...
33 RedeNeural.TmpMaxMin - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16
34 Linear.TmpMaxMin - 2021-12-21 13:48:37 - Executando previsoes...
35 Linear.TmpMaxMin - 2021-12-21 13:48:37 - Prevendo demanda media para 2021-06-16
36 RedeNeural.TmpMaxima - 2021-12-21 13:48:37 - Prevendo perfil para 2021-06-16
37 RedeNeural.TmpMaxMin - 2021-12-21 13:48:37 - Prevendo perfil para 2021-06-16
38 Radial.TmpMaxima - 2021-12-21 13:48:38 - Prevendo perfil para 2021-06-16
39 Radial.TmpMaxMin - 2021-12-21 13:48:38 - Prevendo perfil para 2021-06-16
40 Linear.TmpMaxima - 2021-12-21 13:48:38 - Prevendo perfil para 2021-06-16
41 Linear.TmpMaxMin - 2021-12-21 13:48:39 - Prevendo perfil para 2021-06-16
42 RedeNeural.TmpMaxima - 2021-12-21 13:49:01 - Prevendo demanda media para 2021-06-17
43 RedeNeural.TmpMaxima - 2021-12-21 13:49:01 - Prevendo perfil para 2021-06-17
44 RedeNeural.TmpMaxMin - 2021-12-21 13:49:01 - Prevendo demanda media para 2021-06-17
45 RedeNeural.TmpMaxMin - 2021-12-21 13:49:02 - Prevendo perfil para 2021-06-17
```

Figura 20 – Arquivo DataHora_log_prevcargadessem.txt com log de execução do PrecvargaDESSEM 2.0

Referências bibliográficas

-
- Bates, J. M.; Granger, C. W. J. The combination of forecasts. Operations Research Quarterly, 20:451–468, 1969.
- Dubinsky, A.; Elperin, T. A method for calculating a load curve using average values of load over time intervals, International Journal of Electrical Power & Energy Systems, v. 19, n. 6, pp. 393-395, August, 1997.
- Hamel, L. Knowledge discovery with support vector machines, Wiley, 2009.
- Haykin, S. Neural networks and learning machines, Third Upper Saddle River, NJ: Pearson Education, 2009.
- Hong, T., Gui, M., Baran, M.E., Willis H.L. Modeling and forecasting hourly electric load by multiple linear regression with interactions, IEEE PES General Meeting, 25-29 July, Minneapolis, 2010.
- Hyndman, R.J.; Athanasopoulos, G. Forecasting principles e practice, third edition, OTexts, 2021.
- Kovács, Z.L. Redes Neurais Artificiais: fundamentos e aplicações, São Paulo: Edição Acadêmica, 1996.
- R Core Team, R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. URL <https://www.R-project.org/>, 2017
- Smola, A.J; Scholkopf, B. A Tutorial on Support Vector Regression, Journal Statistics and Computing, Volume 14 Issue 3, Pages 199-222, August 2004.
- Vapnik, V.N.; Boser, E.B.; Guyon, I.M.; Training Algorithm for Optimal Margin Classifiers, Proceedings of the fifth annual workshop on Computational learning theory, Pages 144-152, Pennsylvania, July 1992.
- Werbos, P.J. Backpropagation through time: What it does and how to do it, Proceedings of the IEEE, v. 78, n. 10, October, 1990.
- Yadav, S.; Shukla, S. Analysis of k-Fold Cross-Validation over Hold-Out Validation on Colossal Datasets for Quality Classification, Advanced Computing (IACC), 2016 IEEE 6th International Conference on, February 2016.
- Zhang, G.; Patuwo, B.E.; Hu, M.Y. Forecasting with artificial neural networks: The state of the art, International Journal of Forecasting, 14, pp. 35-62, 1998.